

Západočeská univerzita v Plzni
Fakulta aplikovaných věd
Katedra informatiky a výpočetní techniky

Diplomová práce

Nástroj pro automatickou identifikaci KIR alel

Místo této strany bude
zadání práce.

Prohlášení

Prohlašuji, že jsem diplomovou práci vypracovala samostatně a výhradně s použitím citovaných pramenů.

V Plzni dne 15. července 2020

Kateřina Kratochvílová

Poděkování

Ráda bych poděkovala Ing. Lucii Houdové, Ph.D. za cenné rady, věcné připomínky, trpělivost a ochotu, kterou mi v průběhu zpracování této práce věnovala. Dále bych chtěla poděkovat panu Ing. Jiřímu Fatkovi za jeho rady a pomoc při vytváření praktické části.

Abstract

The text of the abstract (in English). It contains the English translation of the thesis title and a short description of the thesis. Text abstraktu (česky). Obsahuje krátkou anotaci (cca 10 řádek) v češtině. Budete ji potřebovat i při vyplňování údajů o bakalářské práci ve STAGu. Český i anglický abstrakt by měly být na stejné stránce a měly by si obsahem co možná nejvíce odpovídat (samozřejmě není možný doslovný překlad!).

Abstrakt

Diplomová práce se zabývá identifikací KIR alel. Cílem práce je vytvořit nástroj pro jejich automatickou identifikaci. V práci byli analyzovány KIR geny a metody získávání dat z DNA, konkrétně next-generation sequencing (NGS). Dále byly analyzovány bioinformatické nástroje se zaměřením na nástroje ART a Bowtie. Vytvoření syntetických readů, které byly následně použity na testování probíhalo pomocí nástroje ART. Nástroj Bowtie byl použit pro zarovávání readů (kusů DNA) na referenční DNA. Nástroj pro identifikaci byl vyvíjen na syntetických readech a nakonec testován na datech komerčních linií DNA získaných z FN Plzeň/BC LF UK Plzeň.

Obsah

1	Úvod	8
2	Imunitní systém a jeho spojitost s geny	9
2.1	Geny	9
2.2	HLA a non-HLA geny	10
2.2.1	Alela a gen	12
2.3	Natural killer a jeho receptory	13
2.3.1	NKG2D receptor	13
2.3.2	KIR receptor	14
3	Sekvenační metody získávání DNA dat	21
3.1	Sanger sequencing	21
3.2	NGS next-generation sekvenování	22
3.2.1	Single-end, paired-end a mate-pair	23
3.2.2	454 sekvenování a Ion Torrent	23
3.2.3	Illumina	24
3.2.4	SOLiD	25
3.3	Metody třetí generace	25
4	Analyza dostupných bioinformatických nástrojů pro zpracování NGS dat	26
4.1	Simulační nástroje pro generování syntetických readů	26
4.1.1	ART	27
4.2	Nástroje pro zarovnávání readů	28
4.2.1	Bowtie2	29
4.2.2	Burrows-Wheeler transformace	32
4.3	Další pomocné metody	34
4.3.1	Levenshteinova vzdálenost	34
5	Implementace	35
5.1	Popis problému	35
5.2	Referenční geny	35
5.3	Testovací genotypy	36
5.4	Návrh systému	36
5.4.1	Použité programové prostředky	37
5.4.2	Bordel	37

5.5	Modulové jednotky programu	38
5.5.1	Config	38
5.5.2	Simulování dat	38
5.5.3	Zarovnání vzhledem k referenčním genům	39
5.5.4	Vyhodnocení zarovnání	39
5.5.5	Překlad alel	43
5.6	Nastavení ART a bowtie	43
6	vyhodnocení mezi výsledku a nastavení parametru	44
7	Vyhodnocení výsledků a jejich srovnání	56
8	Závěr	57
9	Výkladový slovník pojmů a zkratk	58
	Literatura	60
A	Uživatelská dokumentace	63
A.1	Spuštění programu	64
A.2	Doporučená adresářová struktura pro data	64
A.3	Výstupy programu	64
A.4	Nastavení ART a jeho spuštění	65
A.4.1	pokus to nějak spustit	65
A.5	Bowtie	65
A.6	Používané soubory	66
A.6.1	FASTQ	66
A.6.2	FASTQ	67
B	Detailní výsledky	68
B.1	Experiment1	69
C	Vyhodit	72

1 Úvod

Transplantace krvetvorných buněk se využívá jako terapeutická procedura pro mnoho vážných hematologických poruch mezi které patří například akutní myeloidní leukemie. Transplantace je proces při kterém jsou dárce odebrány krvetvorné buňky které jsou následně vpraveny do těla pacienta trpícím hematologickou poruchou. Jednou z komplikací, která může nastat je reakce imunitního systému na nově vložené dárcovské buňky resp. štěp. V případě, že si štěp s imunitním systémem nebudou rozumět, může dojít k silné zánětlivé reakci, která může skončit až smrtí pacienta. V neposlední řadě může dojít také k relapsu onemocnění (návrat nemoci).

K potlačení odmítnutí dárcovského štěpu se primárně vybírají dárce podle shody v HLA znacích následovaných sekundárními znaky, které mohou být například věk či pohlaví. Shoda v HLA genech se určuje podle shody v alelách genů HLA -A, -B, -C, -DRB1, -DQB1. Alela je konkrétní forma genu. Každý jedinec má tyto HLA geny dvakrát (jednu pěticí od matky a druhou od otce) a proto se úplná shoda označuje jako 10/10. V poslední době se množí studie, které prokazují vliv i takzvaných non-HLA genů. Jedním z nich může být i skupina genů Killer-cell immunoglobulin-like receptor (KIR). Jednou z výhod je, že určité seskupení KIR genů snižuje riziko návratu nemoci. V případě, kdy by se rozhodovalo mezi více dárce by se mohl ten vhodnější vybrat právě na základě KIR. Pro zjištění jak HLA znaků tak KIR genů se využívají sekvenční metody. V případě kdy by bylo nalezeno více vhodných dárců v HLA znacích, tj. se shodou 10/10 nebo 9/10, vybíralo by se následně podle KIR genů. [21] [12]

Cílem práce je navrhnout a implementovat nástroj pro automatickou identifikaci KIR alel. Vstupní data tzv. ready jsou neznámý kus DNA (posloupnost písmen A, C, G a T) a jsou výstupem ze sekvenčních technik. Nikdo přesně neví co znamenají. Může to být gen, část genu nebo několik různých genů. Význam readu (o jaký gen se jedná) se zjišťuje zarovnáváním, kdy se daná sekvence porovnává vůči referenčnímu genu. Ready budou pro vývoj nástroje simulována a v konečné fázi testování budou vyměněna za data z FN Plzeň/BC LF UK Plzeň. V poslední fázi bude vyhodnocena shoda readů a referenčních genů.

2 Imunitní systém a jeho spojitost s geny

Imunitní systém chrání organismus před škodlivinami. Skládá se ze dvou hlavních částí vrozené imunity a získané imunity. Reakce imunitního systému je vždy komplexní reakce organismu mezi jednotlivými buňkami imunitního systému reagující na přítomnost specifických antigenů. Antigeny jsou látky, které imunitní systém rozpozná a zareaguje na ně. V podstatě to může být jakákoli bílkovinná sloučenina. Antigen se obvykle nachází na povrchu buňky jako vyjádření genu. Imunitní systém následně zjistí o jaký antigen se jedná, respektive o jakou buňku se jedná, zda tělu vlastní (např. zdravá buňka) nebo buňku tělu cizí (např. nádorová buňka), tedy jedná-li se o exprese lidského genu nebo například viru. Jedná-li se o buňku tělu cizí imunitní systém reaguje snahou ji zničit.


Vrozená imunita též označována přirozená, neadaptivní, antigenně nespecifická je neměnně zapsána v DNA. To znamená, že při každém setkání s antigenem odpoví stejnou reakcí. Buňky nesoucí vrozenou imunitu jsou stále přítomně v krvi, takže jejich případná aktivace je takřka okamžitá (minuty až hodiny). Do této imunity patří i natural killer buňky s KIR receptory, které budou dále rozebírány v textu.

Získaná imunita též označována specifická či adaptivní oproti specifické má v genomu zapsány pouze své základy. V průběhu lidského života se vyvíjí a mění. Změna může nastat například očkování nebo proděláním příčinné choroby. Tato změna ovšem nemusí být trvalá. Z těchto důvodů může být odpověď získané imunity při setkání se stejnou chorobou rozdílná. Fungování získané imunity zajišťují T- a B- lymfocyty, ale nefunguje samostatně. Při zabíjení patogenů spolupracuje s vrozenou imunitou.

2.1 Geny

V každé buňce lidského organismu, konkrétně v buněčném jádře, je možné nálezt 46 chromozomů. Jeden chromozom představuje stočenou dlouhou molekulu DNA (Deoxyribonukleovou kyselinu). Všechny 46 chromozomů obsahují okolo 100 000 genů. Drobný segment DNA, který řídí buněčnou funkci

je právě gen. Konkrétní forma genu je alela. [28]



Obrázek 2.1: Převzato z [4] a [1]

Uvnitř buňky máme celý genom, který se ovšem nemusí projevit na povrchu buňky. Pokud se vlastnost, kterou gen přenáší projeví na povrchu buňky označujeme to jako exprese genu (jeho sebevyjádření). Od toho se odvíjí i konkrétní názvosloví typu gen, receptor či molekula.

2.2 HLA a non-HLA geny

Human leucocyte antigen (HLA) je genetický systém, který je primárně zodpovědný za rozeznávání vlastního od cizorodého. Někdy je termín HLA zaměňován s MHC. MHC (Major histocompatibility complex) je souhrnný termín pro všechny komplexy, kdy podskupinou jsou právě HLA (H - Human) který je pro lidi. Stejně tak existuje DLA (D - Dog) který je pro psy. Z funkčního i biologického hlediska jde však u všech savců o stejnou skupinu genů. [21]

Přesná definice mezi HLA a non-HLA geny neexistuje. Mimo jiné i jejich rozdělení není v literaturách sjednocené. Jak je vidět z obrázku 2.2 je možné geny rozdělit do tří tříd. V některých literaturách je možné nalést označení non-HLA genů jako geny III. třídy v jiné, že jsou to všechny geny III třídy a některé geny třídy I. Tato práce bude vycházet v označení gen za non-HLA či HLA z definice uvedené v [26]. Zjednodušeně tedy můžeme říci, že geny které nejsou řazeny k HLA skupinám jsou non-HLA. Je-li gen označen za non-HLA neznamena to, že by neměl souvislost s funkcí imunitního systému. Naopak má, jen ne výlučně s HLA systémem. Non-HLA geny kódují produkty spojené s imunitními procesy. Mezi non-HLA geny mimo jiné patří MICA, MICB a KIR. [26]

V posledních letech se objevuje Haploidentická transplantace, kdy je možné použít krvetvorné buňky příbuzného se shodou pouze jednoho haplotypu (5/10) například všichni rodiče a děti. Umožňuje to podávání chemoterapie pár dní po transplantaci, která zničí všechny buňky, které tělo nepřijme. Využívá se toho hlavně v případech časové tísně, kdy není čas hledat dárce v registrech. [3]

2.2.1 Alela a gen

Alelu můžeme definovat jako variantu genu s nepatrným rozdílemem v sekvenci nukleotidů DNA oproti jiné alele stejného genu. Jinak řečeno alely jsou varianty genu na molekulární úrovni. Geny se zpravidla vyskytují minimálně ve dvou formách (dvou alelách). Gen určuje výskyt nějakého znaku, například oči konkrétního živočicha budou mít barvu. Alela pak určuje jaká barva to bude.

V případě genu *KIR2DL1* mohou být jeho alely 0010101 a 0010102. Zápis genů tak, jak s nimi budeme pracovat může vypadat způsobem zobrazeným v 2.2.1.

$$\begin{aligned} > KIR : KIR00001 KIR2DL1 * 0010101 14738 bp \\ GTTCGGGAGGTTGGATCTCAGACGTG... \end{aligned} \quad (2.2.1)$$


Označení *KIR : KIR00001* označuje pořadové číslo, kdy alela byla nalezena. Oproti tomu *KIR2DL1 * 0010101* je označení genu podle jeho vlastností.

Alela zajišťuje konkrétní fenotypový projev genu. U jedince mohou na homologních jaderných chromozomech být přítomny pouze dvě alely. Když jsou v párových lokusech obě alely shodné, jde buď o dominantního homozygota (AA) nebo o recesivního homozygota (aa). Když jsou na párových chromozomech v daném lokusu přítomny různé alely, jde o heterozygota (Aa). Značení alel vzniká dohodou. Příklad značení je uveden dále v rámci nomenklatury KIR genů.

K zjištění konkrétních alelických variant se pro tzv. typizaci využívají sekvenační metody, typicky s polymerázovou řetězovou reakcí.

2.3 Natural killer a jeho receptory

Natural killer buňky (NK buňky) jsou velké granulární lymfocyty vrozeného imunitního systému. V krevním oběhu lidského těla je jich možné nalést 10 – 15%. Klíčovou vlastností NK buněk je nejenom schopnost rozlišit poškozené buňky od zdravích, ale i poškozené buňky rychle a efektivně likvidovat. Poškozené buňky mohou být buňky infokované virem či buňky transformované v nádorové. Na povrchu NK buňky se nachází receptory, které jsou zobrazeny na obrázku 2.3, regulující odpověď imunitního systému. Natural killer buňky oproti B- a T- lymfocytům (buňkám získané imunity) nemají antigenně specifické receptory. Jedním ze způsobů jak NK buňky rozpoznávají a zabíjejí poškozené buňky je na základě interakce mezi KIR receptorem a HLA molekulou na povrchu zkoumané buňky (podrobněji viz sekce KIR). Stejně tak mohou zabíjet na základě receptoru NKG2D, který aktivuje cytotoxickou reakci při setkání s ligandem MICA a MICB. Ligandem označujeme malou molekulu, která se váže na vazebné místo cílového proteinu(receptoru) a vyvolává fyziologickou odpověď, která může mít inhičinní či aktivační charakter.



Obrázek 2.3: Natural killer buňka a její receptory, rozděleny na aktivační a inhičinní.[9]


2.3.1 NKG2D receptor

NKG2D je jeden z nejvýznamnějších aktivačních receptorů na NK buňce rozpoznávající především buněčný stres, který může spustit cytotoxicitu (schopnost ničit buňky), i když se na povrchu buňky nachází inhičinní HLA-I ligandy.

Geny skupiny MICA a MICB jsou označeny jako class I chain-related gene. To znamená, že se běžně neřadí do I. třídy MHC. Takto označované geny mají souvislost s MHC I. třídy, ale narozdíl od nich neváží peptidy. Oproti HLA genům, které mají svoje produkty na lymfocytech, se produkty MICA a MICB nachází na epitelových buňkách. Nejedná se tedy o standardní HLA geny, proto jsou nověji v literaturách označovány jako non-HLA. Jejich expresí na povrch buňky jsou ligandy, které se váží na receptor NKG2D. Buňky s ligandy MICA a MICB se množí při nádorovém onemocnění, zanětu nebo pod vlivem různých forem buněčného stresu a díky navázáním na receptor může být spuštěna imunitní reakce. [24] [13] [9] [26]

2.3.2 KIR receptor

Killer immunoglobulin-like receptor (KIR) je skupina genů řazených mezi non-HLA geny. Jejich zvláštností je fakt, že se nenachází na 6 chromozomu, ale na 19 a tak shodní dárci HLA znaků mohou být neshodní v KIR znacích. Expresí KIR genů jsou receptory na povrchu natural killer buněk. Dnes je známo 15 genů a 2 pseudogeny rozlišujících se na inhibiční a aktivační na základě cytoplasmatického ocásku a počtu imunoglobulinových domén. [21]



Obrázek 2.4: KIR se nachází na 19 chromozomu v oblásni jménem leukocyte receptor complex (LRC). [26]


Nomenklatura KIR genů

KIR geny (na obrázku 2.5) se liší různou délkou cytoplasmatických ocásku (tail) a různým počtem imunoglobulin-like domén (lg-like). Na základě této rozmanitosti byla založena nomenklatura KIR genů, tedy jejich pojmenování.

Jak je vidět na obrázku 2.5, cytoplasmatický ocásek může být dlouhý (long - L) nebo krátký (short - S). Je možné se setkat i s označením P, které slouží pro pseudogeny. Oproti tomu imunoglobulinové domény se mohou vyskytovat 2 (2D) nebo 3 (3D). Právě z těchto vlastností vychází základ pojmenování KIR genů.

Příkladem může být KIR2DL1*010101, kde 2D označuje dvě imunoglobu-

linové domény, L značí dlouhý ocásek, 1 značí že je to první 2DL protein. Numerická definice alely je poté oddělena hvězdičkou. První tři čísla označují alely, které se liší v sekvencích jejich kódovaných proteinů, další dvě číslice se používají k rozlišení alel, které se liší synonymními rozdíly v kódující sekvenci. Konečné dvě cifry rozlišují alely na základě substituce v intronu, promotoru nebo jiné nekódující oblasti. [26]




Obrázek 2.5: Nomenklatura KIR genů. [21]

Další rozdělení KIR genů je na již výše zmíněné inhibiční a aktivační. Dle obrázků 2.3 a 2.5 je možné si povšimnout detailu, že až na KIR2DL4 jsou aktivační KIR s krátkým ocáskem, zatímco inhibiční jsou s dlouhým ocáskem.

Aktivace NK buněk pomocí KIR

Jak již bylo výše zmíněno, KIR receptory můžeme rozdělit na inhibiční a aktivační. Zda dojde k aktivaci NK buňky rozhoduje právě jejich rovnováha na zkoumané buňce. Obrázek 2.6 uvádí vazebné ligandy pro jednotlivé KIR receptory.




Obrázek 2.6: KIR geny a jejich vazebné ligandy. Pokud je v obrázku ?, značí to, že pro daný receptor není znám vazebný ligand. [29]

NK buňky ustavičně prohledávají své okolí a testují přítomnost příslušných HLA ligand pro své KIR receptory. Pokud je příslušný HLA ligand přítomen, naváže se na NK buňku (2.7 případ 1). Tímto systémem jsou ochráněny vlastní buňky. Pokud přítomen není, je spuštěna cytotoxická reakce a zkoumaná buňka je zničena.

Některé virem napadené buňky potlačují propsání HLA ligandu na povrch buňky a tím se brání cytotoxicitě proti T lymfocytům, ale tím jsou naopak více citlivější na cytotoxicitu proti NK buňkám, jak je zobrazeno na obrázku 2.7 případ 3.

The NK Cell is like a border patrol agent

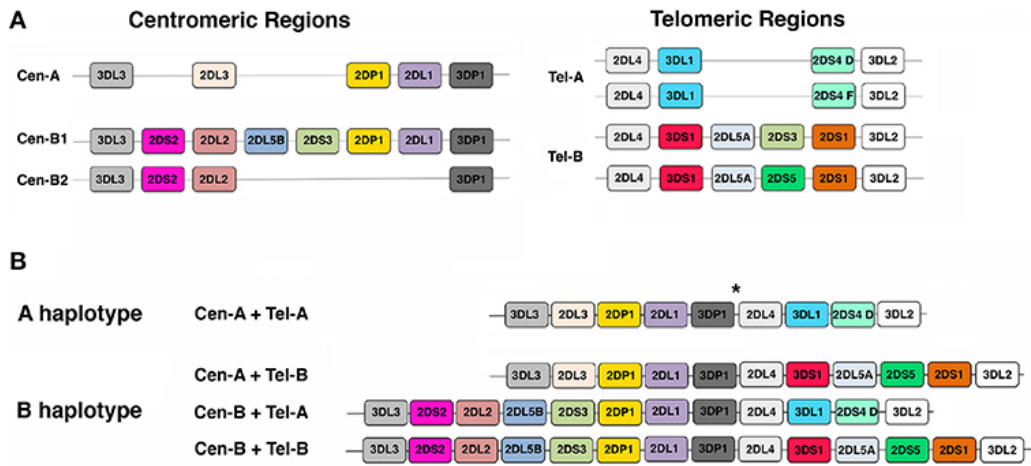


Obrázek 2.7: Přirovnání fungování natural killer buňky k pasové kontrole. V pravé části jsou zobrazené případy, které mohou nastat když natural killer buňka potká jinou buňku. V 1. případě je tělu vlastní zdravá buňka, kde se KIR receptor naváže na HLA ligand a k cytotoxické reakci nedojde. Druhým případem je červená krvinka. K reakci NK buňky opět nedojde, protože na zkoumané buňce nepřevažují aktivační receptory. V 3 případě je to nádorová buňka, která schová HLA ligand (může nastat po transplantaci kostní dřeně) a tím se "schová" proti T-lymfocytům. Avšak aktivační receptory převažují a tak k cytotoxicitě dojde. Ve 4 příkladě je nádorová buňka nebo virem nakažená buňka (stresové ligandy). Aktivační receptory převažují k cytotoxické reakci dojde.[27]

KIR genotyp a haplotyp

KIR genotyp je vyjádření, jaké konkrétní KIR geny genom obsahuje. Genotyp je možné rozdělit na dvě části, takzvané haplotypy. Jeden haplotyp je od otce, druhý je od matky. Na základě kombinací všech genů je možné vytvořit velký počet KIR genotypů. Proto byl díky shromážděným haplotypům sestaven model, který toto množství mírně redukuje, samozřejmě existují vzácné varianty, které se do tohoto modelu nehodí. Haplotyp se rozděluje na dvě části, centrometickou a telometrickou v závislosti zda je blíže k centroměře

či telomeře. Jednotlivé části mezi sebou mohou být kombinovány. Centromerická i telomerická část může být zařazena do jedné ze dvou skupin A či B na základě genů které obsahuje (viz. obrázek 2.8 část A). Celý haplotyp je následně přiřazen do jedné z dvou skupin podle kombinace centromerické a telomerické části. V případě, kdy jsou obě části A/A je haplotyp označen za A, v ostatních kombinacích (A/B, B/A, B/B) je haplotyp B (viz. obrázek 2.8 část B). Jiná definice pro rozdělení haplotypů uvádí, že skupina B musí obsahovat alespoň jeden z genů KIR2DL5, KIR2DS1, KIR2DS2, KIR2DS3, KIR2DS5 a KIR3DS1. Naopak skupina A neobsahuje ani jeden z těchto genů. Je třeba si zde uvědomit, že každý jedinec má 2 KIR haplotypy. [23]



Obrázek 2.8: Rozdělení KIR genů na centrometrickou a telometrickou část, pojmenování je na základě, zda je úsek blíže k centromeru nebo k telomeru (viz obrázek 2.1). Je možné si zde povšimnout, že je možné některé geny najít jak v centromerické části tak v telomerické části. Upraveno z [23]

Podle některých studií zabývajících se vlivem KIR haplotypů na výsledky transplantace bylo zjištěno, že KIR haplotypy ovlivňují výsledky u akutní myeloidní leukémie či lymfoblastické leukémie. Ve srovnání s haplotypem A měl haplotyp B, především jeho centrometrická část, ochranný účinek před návratem nemoci a zároveň zvýšil pravděpodobnost přežití pacienta. Na základě této skutečnosti se mohou dárci řadit do tří skupin best, better a neutral. Rozřazení do třídy se vyhodnocuje jako počet B a jejich umístění, v centromerické oblasti či telomerické oblasti. Mimo jiné je možné se setkat s pojmem B-skóre. Toto číslo udává počet B, které se v daném haplotypu nachází. Best je definován s B-skórem alespoň 2, přičemž dvě B se musejí

nacházet v centromerické oblasti Cen-B/B a Tel-x/x. Better je definován s B-skórem alespoň 2, aby nebyl haplotyp zařazen do Best musí být logicky alespoň jedna z Centromerických oblastí A - Cen-A/x a Tel-B/x. Neutral je v případě jedné B části nebo žádné. [10]

KIR geny se stejně jako HLA dědí celý blok. Jelikož HLA se nachází na 6 chromozomu a KIR na 19, tak shodní dárce v HLA znacích se jen menšinově shodují v KIR genech. V případě příbuzného dárce shodujícího se v HLA znacích je pouze 25% shodných také v KIR. [10]

Hapl Group	Genotype ID ¹	3DL1	2DL1	2DL3	2DS4	2DL2	2DL5	3DS1	2DS1	2DS2	2DS3	2DS5	2DL4	3DL2	3DL3	2DP1	3DP1	Populations	Individuals
AA	1																	190	7,540
Bx	2																	178	2,522
Bx	4																	178	2,096
Bx	3																	167	1,157
Bx	5																	161	1,536
Bx	6																	155	899
Bx	7																	134	583
Bx	8																	130	635
Bx	9																	120	395
Bx	71																	112	443

Obrázek 2.9: Deset nejčastější KIR haplotypů. Šedý obdelník značí přítomnost genu, bílý jeho nepřítomnost. [6]

3 Sekvenační metody získávání DNA dat

Po pojmem sekvence DNA se skrývá posloupnost písmen představujících primární strukturu reálné nebo hypotetické molekuly či vlákna DNA, které nese nějakou informaci. Jednotlivá písmena jsou označována jako nukleotidy nebo nukleové báze. Nukleové báze mohou být A - adenin, C - cytosin, G - guanin a T - thymin. [2]

Příkladem může být následující úsek sekvence na základě obrázku 2.1


ACGTCA (3.0.1)

Sekvenování DNA, někdy pouze sekvenování, jsou biochemické metody, kterými se zjišťuje pořadí nukleotidů (A, C, G, T) v sekvenci DNA. Díky tomu je možné zjistit typizaci konkrétního člověka. Sekvenační metody se liší zejména délkou řetězce, kterou dokáží zpracovat, cenou a rychlostí sekvenace. Pro porovnání, sekvenování celého genomu Sangerovou metodou by stálo několik milion dolarů a trvalo zhruba 10 let. Při použití dnešních metod by cena byla zhruba tisíc dolarů. Většina sekvenačních metod využívá vlastnosti přitahování báze do páru pouze jednou konkrétní bází. To znamená že se adenin vždy páruje s thyminem a cytosin se vždy páruje s guaninem. Z těchto párů vzniká již známá dvojité šroubovice DNA. Při sekvenování je možná se často setkat, že se sekvenuje jen konkrétní kus DNA, který je zrovna výzkumně či prakticky potřeba. Největším problémem u sekvenování je, že úseky DNA vzniklé ze sekvenátoru (označovány jako ready) jsou jen kousky, které je třeba poskládat zpět. K tomu slouží zarovnávání. [16]

3.1 Sanger sequencing

Sanger sekvenování využívá možnosti namnožení řetězce díky vzájemnému přitahování konkrétních bází. V prvním kroce replikace jsou nastříhané řetězce rozděleny na dvě vlákna. Lze si představit, že tyto dvě oddělená vlákna jsou dána do směsy, kde plavou jednotlivé nukleotydy spolu s upravenými nukleotidy, které nesou specifickou fluorescenční barvu a za které není možné nic navázat. Následně za pomoci střídání teploty volně plující nukleotidy tvoří postupné páry s řetězcem, který chceme namnožit. Pokud se povede

celý řetězec namnožit je odtržen a může se dále množit. Postupně ale bude docházet k navazování nukleotidů s fluorescenční barvou. Tím se vytvoří několik různě dlouhých sekvencí zakončených označeným nukleotidem. Podle jeho barvy je možné poznat o jaký nukleotid se jedná. Následně jsou za pomoci elektroforézy seřazeny v gelu podle délky. Elektroforéza rozděluje různě dlouhé sekvence na základě odlišnosti pohybu v elektrickém poli. Kratší doputují dále než delší. Pomocí sanger metody je možné sekvenovat řetězce dlouhé až 1000 bází.



Obrázek 3.1: Elektroforéza. [22]

3.2 NGS next-generation sekvenování

Next-generation sekvenování někdy označováno jako metody druhé generace jsou v porovnání se Sangerovo sekvenováním rychlejší a levnější, na druhou stranu ale dokáží zpracovávat jen řetězce dlouhé 100 až 500 bází, mají menší přesnost a častěji chybují. Jejich rychlost spočívá především ve schopnosti detekovat přidávání bází jednu po druhé a zároveň sekvenovat tisíce až miliony rozdílných molekul DNA najednou.

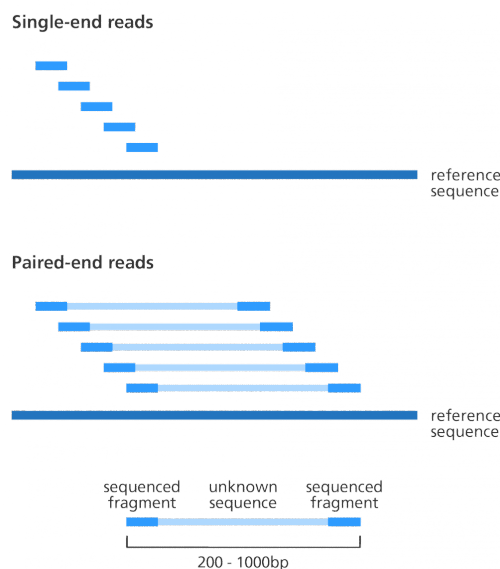
Všechny tyto metody si předpřipraví řetězce nastříháním na krátké části a připevněním takzvaného adeptéru na jejich konec. Adaptér je krátká molekula DNA, která slouží k uchycení sekvenovaného úseku na pevný povrch. Řetězce DNA jsou namnoženy díky čemuž vzniknout klastry identických molekul koncentrovaných v jednom místě. Díky tomu je posílen signál, který by z pouhé jedné molekuly nebyl dostatečně silný. Tento signál je zachycen kamerou. Jeden z důvodů popularity NGS metod jsou i cenově dostupné

stolní sekvenátory.

3.2.1 Single-end, paired-end a mate-pair

Single-end je sekvenování pouze jednoho konce molekuly. Nevýhoda tohoto způsobu se projeví především na krátkých readech, kde se zvýší problém jejich správného umístění. Oproti tomu v případě paired-end se sekvenuje z obou konců daného úseku. Vzniklé dva ready jsou označeny a zároveň je známá jejich vzdálenost, která se pohybuje od 200 do 400 bp (base pair). Mate-pair je v podstatě paired-end s rozdílem, že je mezi ready větší vzdálenosti od 2 do 5 kb (kilobase) - takže přibližně 2000 - 5000 bp. [5]

TODO obrázek je z trochu blbího zdroje nejsem si jistá jestli ho můžu použít, ale mě přišel dobřej. <https://www.yourgenome.org/facts/how-do-you-put-a-genome-back-together>
Image credit: Genome Research Limited - obrázek lze použít, nutná správná citace, popř. najít originál




Obrázek 3.2: Single-end a paired-end read.

3.2.2 454 sekvenování a Ion Torrent

Pomocí 454 sekvenování je možné analyzovat více než milion molekul DNA najednou a délka každé jednotlivé sekvence se pohybuje okolo 700 až 1000 bází. V prvním kroku sekvenování je fragment DNA přichycena na malou "kuličku" na jejímž povrchu se postupně namnoží až kuličku zcela pokryjí identické fragmenty DNA. Následuje vložení kuličky i s DNA do jedné z

milionů komůrek na destičce s reakční směsí. Postup znázorněn na obrázku 3.3. V určitém momentě je do této směsi přidán vždy jen jeden typ báze. Mezi jednotlivými fázemi přidávání určité báze jsou přebytečné nukleotidy z předešlého kroku odstraněny. To znamená že v reakční směsi je vždy jen jeden typ nukleotidů. Během vložení každé nové báze do rostoucího řetězce DNA je uvolněna molekula zvaná pyrofosfát, která spustí několik chemických reakcí. V poslední fázi enzym luciferáza vydá světelný záblesk, který je možné zachytit citlivou kamerou. Tento postup se nazývá pyrosequencing. V případě, kdy je do řetězce přidáno několik stejných bází za sebou, například gen obsahuje podřetězec AAA, je vyzařeno, v našem případě, třikrát více světla než v případě jedné přiřazené báze. Kamera snímá celou destičku a na základě, která komůrka se rozsvítí pozná, kde proběhlo přidání báze. Intenzita světla pak určuje kolik bází bylo přidáno na jednu.



Obrázek 3.3: 454 sekvenování. [20]

Sekvenování Ion Torrent funguje na podobné principu sekvenování s rozdílem, že místo světla se měří změna pH v reakční směsi. Podle intenzity změny pH lze pak poznat kolik nukleotidů bylo přidáno do rostoucího řetězce.

Hlavní slabinou těchto dvou metod je značná chybovost při přidání mnoha stejných nukleotidů do řetězce za sebou. Například při přidání 10 A, nebude odpověď jednoznačná zda je to 10 A nebo 9.

3.2.3 Illumina

Při sekvenování pomocí Illumina jsou páry dvoušrobovice rozděleny na dva řetězce. Jednotlivé řetězce jsou následně přichyceny na malou destičku po-

mocí adaptéru. Každý řetězec se následně opakovaně množí až na destičce vznikne několik shluků. Přidání jedné molekuly ke druhé probíhá obdobně jako u Sanger sekvenování. Každý shluk tvoří jednu skupinu vzájemně identických řetězců. Mezi volné nukleotidy jsou opět zahrnuty nukleotidy označeny fluorescenční barvou za které nelze nic navázat. Oproti sangerovu sekvenování je ale tato blokace vratná a po přečtení citlivou kamerou dojde k odstranění blokující části molekuly. Počítač si pak následně zpětně spočítá co to bylo za barvu (nukleotid). [5] [16]

3.2.4 SOLiD

SOLiD (Sequencing by Oligonucleotide Ligation and Detection) se spoléhá na enzym ligáza. Enzym je bílkovina, která určuje rychlost chemických reakcí. Enzym ligáza konkrétně umožňuje připojení jednořetězcových molekul k stávajícím řetězcům. K teplátu jsou přidávány takzvané sondy, což jsou kousky DNA. Sondy začínají všemi možnými dvojkombinacemi čtyř základních nukleotidů. V součtu je 16 sond. Na každé sondě je jedna ze čtyř fluorescenčních barev. V jednotlivých krocích jsou sondy připojeny k rostoucímu řetězci. Následně je přečtena fluorescenční barva, která je odstraněna a může se tak navázat další sonda. Z výsledného signálu lze pak odvodit sekvenci DNA.

3.3 Metody třetí generace

Velkým rozdílem oproti druhé generaci je že DNA templát není před sekvenováním namnožen a je čten pouze z jedné původní molekuly. Existuje například PacBio od Pacific Bioscience, který k detekci využívá fluorescenčně značené nukleotidy. Díky jeho vysoké citlivosti je možné v reálném čase zachytit přidání i jediného nukleotidu do jediného řetězce DNA. Další zástupce je Oxford Nanopore jehož výhodou je jeho velikost. Oxford využívá odlišného tvaru bází. Obě metody jsou schopné přečíst přes 10 tisíc bází v rámci jedné analyzované molekuly DNA.

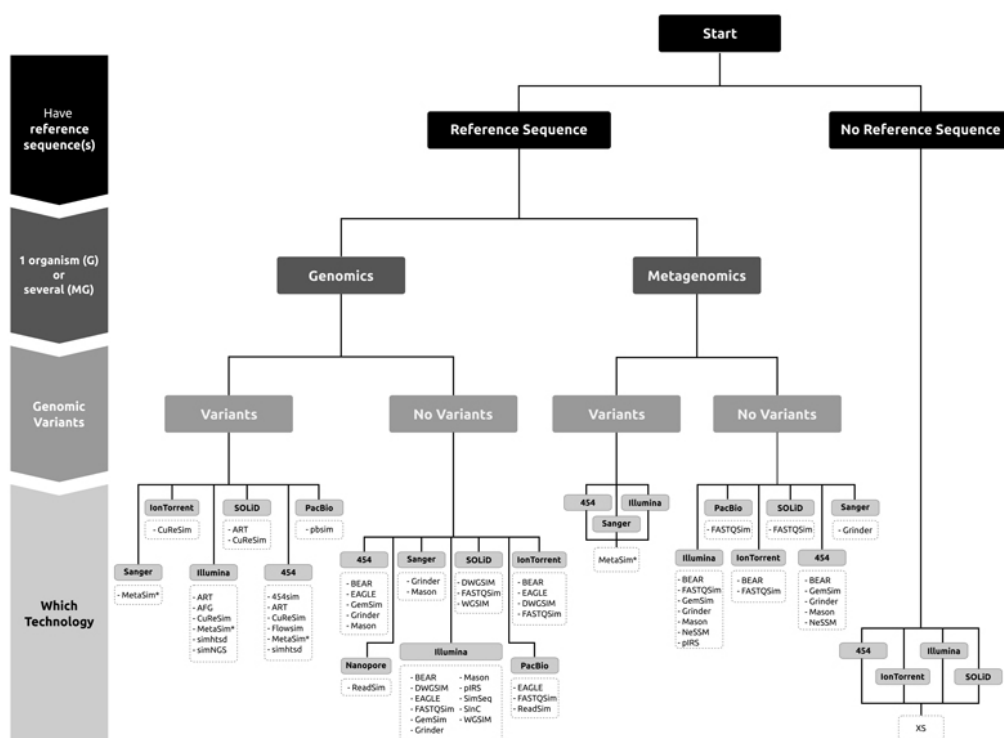
4 Analyza dostupných bioinformatických nástrojů pro zpracování NGS dat

NGS metody snižují náklady a zrychlují proces sekvenování za cenu kratších readů a menší přenosti což vedlo k mnoha bioinformatickým výzvám, jako je vytvoření nástrojů pro analýzu readů. Nástroje je možné mezi sebou porovnat pomocí reálných nebo simulovaných dat. Přestože je validace na reálných datech nezbytná, skutečné hodnoty na kterých jsou data založena jsou obvykle neznámá, což komplikuje jejich použití pro posouzení přesnosti (tj. jak blízko je odhadovaná hodnota ke skutečné hodnotě). Díky tomu je simulování dat čím dál více populární pro hodnocení, validaci či nastavování optimálních parametrů nástroje. [11]

4.1 Simulační nástroje pro generování syntetických readů

Dále uvedené nástroje byly vybrány na základě parametrů: simulování DNA, udržovány a volně dostupné. Následující informace vychází z článku [11] pokud nebude uvedeno jinak.

Většina simulátorů NGS vyžaduje referenční sekvenci ze které budou generovat ready. Tato referenční sekvence může být konkrétní genomická oblast, více zřetězených genomických oblastí, chromozom či celý genom. Některé simulátory vytváří zarovnání readů přímo do referenčníhou souboru (soubory SAM/BAM). Při používání simulátorů může být pro uživatele obtížné se rozhodnout kterou konkrétní hodnotu pro daný parametr určit nebo který vlastní profil vytvořit proto některé simulátory poskytují výchozí profily. Jedním z nich může být i generování chyb či model kvality. Nástroje jako jsou ART nebo SInC generují tyto profily na základě extrahovaných modelů ze skutečných dat. Nejčastější chyby jsou substituční a vložení či smazání (INDEL - insert-deletion).



Obrázek 4.1: Strom pro usnadnění výběru generátoru syntetických readů [11]

Data získaná z FN Plzeň/BC LF UK Plzeň byla sekvenována nástrojem Illumina proto je podle [11] na výběr z ART, AFG, CuReSim, Flowsim, MetaSim, simhtsd a simNGS. U simulátoru AFG je třeba chybové profily definovat ručně, CuReSim a MetaSim nejsou open source, simhtsd podporuje jen operační systém Linux, simNGS podporuje jen operační systémy Linux a MacOS. Proto byl vybrán simulační nástroj ART který podporuje operační systémy Linux, Windows a MacOS. Dále generuje podle chybových profilů a profilů kvality které byly vytvořeny pomocí extrakce chyb získaných ze skutečných dat.

4.1.1 ART

ART (next-generation sequencing read simulator) je sada simulačních nástrojů, které generují syntetické ready, jako kdyby byli získány sekvenováním pomocí NGS. Nástroj ART dokáže simulovat single-end a paired-end ready ze sekvenátorů Illuminas, 454 společnosti Roch a SOLid od společnosti Applied biosystem. Ready, vytvořené nástrojem ART jsou používány pro testování a analýzů nástrojů zpracovávající právě NGS sekvence jako například zarovávání (nástroj Bowtie). Při použití nástroje ART je vstupním


souborem sekvence genů na základě kterých jsou vygenerovány ready. [14]

Illumina je sekvenování založené na vratném umístění báze označené barvou do rostoucího řetězce jehož nejčastější chybou je substituce. Pravděpodobnost chyby substituce je určena na základě kvality skóre dané báze, které je závislé na pozici v rostoucím řetězci. Průměrné kvality skóre klesá v závislosti na zvyšování pozice báze. ART simuluje substituční chybu na základě tohoto skóre a empirického modelu získaného z trénovacích datasetů. INDEL chyba je simulována jen na základě empirického rozdělení z trénovacích dat a u Illuminy se vyskytuje jen zřídka. Pro paired-end simulaci, ART využívá dvou rozdílných kvality skóre pro každý pár readu jiný.

ART je implementován v jazyce C++ a je dostupný s licencí GPL verze 3 pro operační systémy Linux, MacOS a Windows. Je možné ho použít i jako C++ package. Pro jeho spuštění je nutné mít nainstalovaný compiler GNU g++ 4.0 nebo vyšší a knihovnu GNU gsl. Výstupy se čtou ve formátu FASTQ a zarovnání ve formátu ALN. může generovat zarovnávání také ve formátu SAM nebo UCS BED. Paired end ready jsou označeny stejným názvem souboru s 1 či 2 na jeho konci.

4.2 Nástroje pro zarovnávání readů

Zarovnávání bývá prvním krokem v mnoho genomických pipelinech. Často je to jejich nejpomalejší část, protože pro každý read musí zarovnávač vyřešit obtížný výpočetní problém. Určit pravděpodobné umístění v referenčním genomu. V současnosti je na výběr více než 90 nástrojů pro zarovnávání NGS readů. Nástroje jsou mezi sebou obvykle porovnávány na základě přesnosti a rychlosti mapování. V článku [7] bylo porovnáno 5 nástrojů pro zarovnávání DNA readů. Nástroj STAR měl nárůzdíl od ostatních nástrojů menší přesnost, nástroj segemehl byl zase náročný na paměť (podle článku až 70 GB) což se na stolním počítači těžko dosahuje. Ze zbývajících nástrojů byl vybrán nástroj Bowtie2 díky jeho rychlosti vzhledem k nástroji BWA, která vzhledem k množství experimentů bude přínosem.



Obrázek 4.2: Nástroje pro zarovnávání NGS readů. [7]

4.2.1 Bowtie2

Bowtie2 je rychlý a paměťově efektivní nástroj pro zarovnávání krátkých sekvencí DNA na velké genomy. Bowtie2 je schopný zarovnat více než 25 milionů readů dlouhých 35 bp za hodinu (při běhu na jednom CPU) pro lidský genom s malým využitím paměti. Bowtie2 využívá FM indexaci s Burrows-Wheeler transformací (BWT) a přidává k ní backtracking pro sledování nekonzistence. Novější verze Bowtie2 by měla být oproti Bowtie1 citlivější a rychlejší na delší ready než je 50 nukleotidů a navíc je oproti první verzi schopná se vypořádat z chybami vložení či smazání báze způsobené sekvenováním. Na lidský genom potřebuje Bowtie2 3.2 gigabajtů RAM. Nástroj bowtie je implementovaný v jazyce C++ s použitím knihovny SeqAn a je open source. Podporuje standardní vstupní formáty FASTQ a FASTA. Výstupní zárovňování z Bowtie je ve formátu SAM, což umožňuje návaznost s dalšími nástroji jako je třeba SAMtools. Následující informace vychází z článků [19] a [18] pokud není uvedeno jinak.

Mnoho zarovnávačů používá indexy k rychlému snižování kandidátů pro umístění zarovnávaného readu. Bowtie vytváří indexy referenčních genů permanentní a lze je tak použít napříč běhy. Algoritmus FM indexu obvykle funguje na vyhledávání přesně shody. V případě hledání umístění readů na referenční gen není toto řešení použitelné, protože ready mohou obsahovat chyby vzniklé sekvenováním případně genové mutace. Proto Bowtie každé zarovnání zakládá na kvalitě znaku báze v daném readu. Bowtie postupně vytváří dlouhý sufix. Pokud se sufix nevyskytuje v textu pak se může algoritmus vrátit a v již vytvořeném sufixu nahradit bázi za jinou. Dále pokračuje obdobným způsobem. Tento způsob změny báze je dále označován jako backtracking. Pokud by měl algoritmus na výběr substituovat za více bází vybere tu s nejnižší kvalitou znaku v readu. Protože Bowtie algoritmus v základu bere první přijatelné řešení je možné, že jeho nalezené řešení není to nejlepší. Pro nalezení toho nejlepšího řešení je třeba použít přepínač – *best*, jeho funkčnost je ale na úkor rychlosti, která může být 2x či 3x pomalejší. Bohužel nemůže být tento přepínač použit u paired-end readů. Zároveň je možné nastavit maximální počet nahrazených bází v readu. [19]


V případě že backtracking mechanismus není úspěšný může docházet k jeho nadměrnému vyskytu. Bowtie2 se tento jev snaží zmírnit dvojím indexováním. První index obsahuje BWT genomu a je označován jako dopředný index. Druhý obsahuje opět BWT genomu, ale se znaky v sekvenci v opačném pořadí, označován jako zrcadlový index. Read je pak v půlce rozdělen na dvě části a jejich zarovnávání probíhá odděleně tak, že je vždy backtracking povolen jen v dané části, která je zrovna zarovnáвана. Pravá část je zarovnáвана podle dopředného indexu a levá část je zarovnáвана podle zrcadlového indexu.

Předchozí algoritmus funguje dobře pouze v případě, kdy reference nebo read neobsahují mezery (báze chybí nebo naopak přebývá). Proto byl algoritmus rozšířen, jak je popsáno následovně.

4.2.2 Burrows-Wheeler transformace

Burrows-Wheelerova transformace (BWT) je reverzibilní permutace řetězců v textu. Původně byla používána pro kompresy dat. Indexace založená na BWT umožňuje efektivní vyhledávání ve velké textu s malou pamětovou náročností.

BW transformace řetězce T , $BWT(T)$, je zobrazena na obrázku 4.4. Znak $\$$ je připojen na konec řetězce a zároveň musí platit, že se tento znak se v řetězci nevyskytuje. Burrows-Wheeler matice řetězce T je konstruovaná jako všechny cyklické rotace řetězce T , které byly seřazeny podle abecedy, kde znak $\$$ se bere, že je na začátku abecedy. Výstup, $BWT(T)$ pak představuje poslední sloupec matice. Tento řetězec má stejnou délku jako původní řetězec T . [19]



Obrázek 4.4: Burrows-Wheeler transformace řetězce T . [17]


Burrows-Wheeler matice má vlastnost, která se nazývá last first mapping (LF). To znamená, že i -tý výskyt znaku X v prvním sloupci je i -tý výskyt znaku X v posledním sloupci. V případě přidání indexu do řetězce T je toto pravidlo pro znak a zobrazeno na obrázku 4.5. Obdobně to platí i pro ostatní znaky v řetězci.

$$T = a_0 b_0 a_1 a_2 b_1 a_3 \$ \quad (4.2.1)$$

F	L
\$	$a_0 b_0 a_1 a_2 b_1 a_3$
a_3	\$ $a_0 b_0 a_1 a_2 b_1$
a_1	$a_2 b_1 a_3$ \$ $a_0 b_0$
a_2	$b_1 a_3$ \$ $a_0 b_0$ a_1
a_0	$b_0 a_1 a_2 b_1 a_3$ \$
b_1	a_3 \$ $a_0 b_0 a_1$ a_2
b_0	$a_1 a_2 b_1 a_3$ \$ a_0


Obrázek 4.5: Burrows-Wheeler transformace last first mapping (LF). [17]

Zpětné získání řetězce je znázorněno na obrázku 4.6. L sloupec je řetězec, který je výstupem BW transformace. F sloupec je snadné na základě L sloupce odvodit. Jelikož platí pravidlo, že počet jednotlivých znaků je stejný, stačí je pouze přemístit do F sloupce a seřadit podle abecedy. Dále s využitím LF je řetězec získán zpět. Jako první se vezme přidáný znak \$. Ve stejném řádku ve sloupci L se nachází a_0 . To znamená že řetězec začíná \$ a_0 . Algoritmus pokračuje s a_0 v F sloupci. Ve stejném řádku v L sloupci je b_0 . b_0 je přidáno do řetězce a pokračuje až do doby než by byl opět znak \$.



Obrázek 4.6: Burrows-Wheeler transformace zpětné získání původního řetězce. [17]

Díky vztahu mezi F a L sloupcem je možné vyhledávat daný řetězec (zobrazeno na obrázku 4.7). Například vyhledávány řetězec bude $P = aba$. Při pohledu do F sloupce jsou nalezeny všechny sloupce začínající a , následně v L sloupci ve stejných řádcích jsou nalezeny dva výskyty b . Již je získán sufix ba , který existuje. Pokračuje se dále na řádky, které začínají právě nalezenými b . V sloupci L pro dané řádky jsou nalezena a . Řetězec $P = aba$ se v textu vyskytuje.



Obrázek 4.7: FM index - získání prefixu. [17]

4.3 Další pomocné metody

4.3.1 Levenshteinova vzdálenost

Levenshteinova vzdálenost zjišťuje rozdílnost dvou textů na základě počtu změn, které je třeba udělat, aby bylo z jednoho řetězce získán druhý řetzec. Za úpravy se považuje vložení, smazání a nahrazení. Algortimus funguje tak, že se snaží ze slova, které bylo jako první v argumentu vytvořit slovo předáno jako druhé. Příkladem může být vzdálenost mezi řetězci *SPAM* a *PARK*. Vzdálenost těchto slov je 3. Výstup v případě python knihovny je možné vidět následovně. Výstup 4.3.1 je v případě *SPAM*, *PARK*. Výstup 4.3.2 je v případě *PARK*, *SPAM*. Změny jsou definovány: o jakou změnu jde, index znaku v prvním řetězci a index znaku v druhém řetězci. Je možné si všimnout závislosti mezi těmito dvěma postupy. [30]

$$\begin{aligned}
 &('delete', 0, 0), ('insert', 3, 2), ('replace', 3, 3) & (4.3.1) \\
 &SPAM- > _PAM- > _PARM- > PARK
 \end{aligned}$$

$$\begin{aligned}
 &('insert', 0, 0), ('delete', 2, 3), ('replace', 3, 3) & (4.3.2) \\
 &PARK- > SPARK- > SPAR_- > SPAM
 \end{aligned}$$

5 Implementace

5.1 Popis problému

máme krátkou délku že read který dostáváme jsou 250 bp dlouhé a jeden gen může být dlouhý 14738 bp, akorát že z nemocnice ti dají 251 s tím že jednotlivé ready se nám tedy mohou překrývat- tohle si nejsem jistá jestli se můžou překrývat můžou tam být chyby

pak by se tam dala přidat heuristika že bych brala známe haplotypy
Možná pak ještě pracovat s pravděpodobností výskytu daného genu
jenže bowtie může klidně někam zarovnat tam kam to ve skutečnosti napatří protože tam hledá třeba backtracking a nebo vložení a smazání chybu
asi sem dopsat že i ty alely pro jeden gen můžou být různě dlouhé protože tam probíhají mutace

5.2 Referenční geny

Referenční geny byly převzaty z IPD-KIR [26] konkrétně soubory ve formátu *fasta* uloženy ve stejnojmenné složce. Jednotlivé soubory jsou pojmenovány genem, který obsahují např. *KIR2DL1_gen.fasta*. Každý soubor představuje všechny dostupné alely konkrétního genu. Jedinou výjimku tvoří soubory *KIR_gen.**, které obsahují všechny geny a navíc i pseudogeny.

Kromě souborů **_gen.fasta* obsahuje složka *fasta* také soubory **_prot.fast* a **_nuc.fasta*. Soubor *_gen.fasta* obsahuje informace o celých genech. Oproti tomu *_nuc.fasta* obsahuje nucleotidy, tedy pouze exony bez intronů. Soubor **_prot.fast* obsahuje sekvence proteinů, které vznikly z RNA. Data získaná z nemocnice budou odpovídat alelám uvedených v *_gen.fasta*.

Při analýze porovnávání souboru *nuc* a *gen* bylo zjištěno, že v souboru *nuc* je více alel než v souboru *gen*. Konkrétně v souboru *gen* je 461 alel a v souboru *nuc* je 1109 alel. Nejmenší Levenshteinova vzdálenost mezi alelami je 1, největší 15 943 a průměrná 4768.98.

5.3 Testovací genotypy

Genotypy, na kterých byl nástroj testován byly dodány vedoucí práce. Genotypy test1 - test11 byly sestaveny podle definovaných genotypů a umýšlně vybrány ty které představují nějaký problém.

TODO co je sakra: KIR3DS1*049N ???? - Kde jsem to našla v nuc nebo gen?

TODO: KIR_gen.fasta includes the DNA sequence for all alleles, which have genomic sequences available.

TODO sem asi dodat ty věci ohledně dat z nemocnice


TODO ještě dodat že tady asi nebudou všechny známí alely. Musíme porovnat nuc a gen jak jsou ty geny s alelami mezi sebou

5.4 Návrh systému

Systém byl navržen jako modulární, díky tomu je možná jednoduchá náhrada jakékoliv jeho části.

Vše začíná získáním dat pro která má být vyhodnoceno, které KIR alely obsahuje. Buď je možné dostat přímo data z Fakultní nemocnice či biomedicínského centra. To jsou data na kterých bude prováděna verifikace nástroje. Druhou možností je data vyrobit. Na těchto datech byl nástroj vyvíjen a laděn. Data mohou být vyrobena ručně nebo je lze vyrobit za pomoci programu. V dalším kroku musí být haplotyp "rozbit" do podoby jako by vyšel ze sekvenátoru. Rozdělí se na reads a vytvoří s v něm chyby. To se provádí za pomoci nástroje ART.

V následující části jsou získaná data, tedy reads, zarovnána na referenční genom pomocí nástroje Bowtie. Nakonec je zarovnání vyhodnoceno a rozpoznáno o jaké alely genů se pravděpodobně jedná. Vyhodnocení je rozděleno do několika experimentů. Pro zjednodušení práce s výsledky je doplněn krok, kdy jsou názvy alel podle pořadových čísel nahrazeny názvy alel podle jejich skladby.



Obrázek 5.1: Návrh systému. TODO to vyhodnoceni chce předělat. Chybí Bowtie indexy

5.4.1 Použité programové prostředky

Python

Program byl navržen a implementován na operačním systému Linux za použití především programovacího jazyku Python. Pro spuštění programu je nutné mít nainstalovaný Python ve verzi 3.8. TODO dodat knihovny

5.4.2 Bordel

Co znamená konec 3 a konec 5?

5.5 Modulové jednotky programu

Vše potřebné pro samotný běh programu obstarává skript *run.py* spolu s nastavením v souboru *config.py*. Skript *tun.py* postupně pouští jednotlivé moduly. Díky nastavení v *config.py* je možné si zvolit spuštění jen některých modulů. Například pouhé vytvoření testovacích dat nebo pouze jejich zarovnání a v neposlední řadě pouštět vyhodnocování zarovnávaných dat.

5.5.1 Config

S konfiguračním souborem *config.py* jsou spojeny všechny skripty a obsahuje jejich veškerá nastavení. Jak již bylo zmíněno je možné pomocí tohoto nastavení spustit jednotlivé moduly. Jedná se především o položky *CREATE_READS*, která udržuje informaci o spuštění vytvoření syntetických readů. *ALIGN* starající se o spuštění zarovnání a *EVALUATE*, která řídí spuštění vyhodnocení zarovnání. Důležitou položkou v configu jsou cesty ke zdrojovým a výstupním složkám. Dalším nastavením je obsah genotypu při případném vygenerování testovacích dat.

5.5.2 Simulování dat

O simulování dat se stará skript *create_syntetic_reads.py* a je rozděleno na dva kroky: vytvoření genotypů a vytvoření readů. Mezi těmito dvěma fázemi vzniká soubory s příponou *.fa*. Každý tento soubor obsahuje právě jeden KIR genotyp. Tyto genotypy jsou následně použity jako vstupní soubor pro vytvoření readů, které se provádí za pomoci nástroje ART. Pro vytvoření genotypů je volán skript *create_genotype.py*, který vytvoří genotypy na základě nastavení v configu pod položkou *GENOTYPES* a za pomoci referenčních genů v souboru pod položkou v configu *REFERENCE_KIR_GENS_FILE*. Vytvoření probíhá obdobně jako je popsáno níže u ručního vytvoření testovacího genotypu. Výsledné genotypy jsou uloženy do adresáře z configu *GENOTYPE_FOLDER*. Výstupem modulu *create_syntetic_reads* je soubor s příponou *.fq*, který by měl odpovídat formátu reálných dat které byly dodány. Výstupní soubory jsou uloženy do složky pod proměnnou *READS_FOLDER*.

Ruční vytvoření testovacího genotypu lze udělat následujícím způsobem. V prvním kroku je v referenčním souboru vybrána konkrétní alela genu. Někdy je možné najít shodu kdy se alely liší jen v konečné fázi jejich označení a v genotypu je pouze první 5 čísel. S tímto jevem je možné se setkat například v případě alely 3DL3: 00402. V tomto případě může být vložena

jakákoli z těchto alel. Vkladaná alela musí být vložena včetně její hlavičky tedy: `>KIR:KIR00138 KIR3DL3*0040201 12390 bp.`

5.5.3 Zarovnání vzhledem k referenčním genům

Zarovnávání obstarává skript `alignment_reads_to_reference.py` s pomocí nástroje Bowtie2. V nastavení je nutné vyplnit `BOWTIE_HOME_DIRECTORY` podle umístění nástroje Bowtie na konkrétním počítači. V prvním kroku jsou vytvořeny Bowtie indexy, které je možné použít na přích běhy, proto je v nastavení položka `BOWTIE_BUIL_INDEX`, díky které je možné toto vytvoření povolit nebo zakázat. Bez vytvořených indexů, tedy indexů z minulých běhů, ale Bowtie nebude zarovnávat. Bowtie vytváří indexy na základě obsahu souboru `REFERENCE_KIR_GENS_FILE`. V dalším kroku jsou načteny všechny ready ze složky uvedené v `READS_FOLDER` a následně je na ně puštěn nástroj Bowtie. Tady je nutné aby byli ready paired end a to tedy aby se vyskytovali dvakrát jednou z 1 na konci a podruhé s 2. V základu tento předpoklad zajistí správné nastavení ARTU, který je takto nastaven. Výstupní soubory jsou ve formátu `.sam` a jsou umístěny dle položky `ALIGNMENT_FOLDER` v nastavení.

5.5.4 Vyhodnocení zarovnání

Detailní výsledky pro všechny genotypy je možné najít v příloze.

Experiment1

Jako první pokus o určení alel, které by mohli být obsaženy v genomu bylo pouhé oříznutí alel, které by měli větší procentuální šířku zarovnání (například 90%). V případě genotypu amala, která obsahuje 19 alel je výsledek zobrazen níže. Červeně jsou označené alely, které se v genomu skutečně nacházejí, číslo v závorce udává jejich procentuální pokrytí.

- | | |
|-------------------------|-------------------------|
| • 3DL2*0070102 (99.64%) | • 3DL2*0070103 (99.29%) |
| • 2DS4*0010101 (99.64%) | • 3DL3*0040201 (99.22%) |
| • 2DS4*0010102 (99.55%) | • 3DL2*0020106 (99.15%) |
| • 2DS5*0020101 (99.50%) | • 3DP1*007 (99.04%) |
| • 3DL2*0020105 (99.48%) | • 2DS4*0010107 (98.99%) |
| • 2DS2*0010101 (99.43%) | • 2DS5*0020103 (98.98%) |
| • 3DL3*00802 (99.34%) | • 3DS1*055 (98.70%) |

- 3DL2*0020102 (98.40%)
- 3DL2*0020104 (98.19%)
- 3DL2*018 (98.07%)
- 2DL2*0030101 (98.07%)
- 2DP1*0020105 (97.99%)

Následovně jsou uvedeny alely, které do genomu patří, mají pokrytí více než 90%, ale nejsou v prvních 19.

- 2DL2*0030102 (97.29%)
- 2DL3*0010109 (94.16%)
- 2DL5A*00102 (96.6%)
- 2DS1*0020106 (96.57%)
- 3DP1*0090101 (96.46%)
- 3DS1*130101 (95.83%)


TODO Speciálním případem je KIR2DL4*00501 jak začíná několik alel 5 mějí přes 90, další 3 jsou pod 90 viz obrázek? Tady možná zmínit, že tedy stačí zarovnávat na těch 5

Nakonec jsou uvedené alely, které do genomu patří, ale mají pokrytí menší než 90%.



- 2DL1*0030201 (81.8%)
- 3DL1*0150201 (70.71%)

Ná následujícím obrázku jsou zobrazeny všechny alely genu KIR3DS1 a jejich zarovnání. Červeně je označena alela, která do genomu amala patří. Je možné si povšimnout, že alela s největším pokrytím do genomu nepatří. Navíc pokrytí větší než 90% mají všechny alely až na jednu. Neméně důležitá část je, že poslední alela má značně kratší délku než všechny ostatní alely stejného genu. Poslední věcí je hloubka pokrytí, která díky nastavení sekvenátoru by měla odpovídat hladině 100 u alely, která do genu patří. Jak je vidět z obrázku hloubka pokrytí se u většiny alel pohybuje v extrémech kolem 20.

KIR3DS1



Všechny vyše uvedené analýzy navádí na bližší prozkoumání podobnosti alel.
Dát tam upravenej graf Aby byli vidět ty malý vzdálenosti



Experiment2

Experiment2 byl navržen s iterační zarovnávání. V první fázi se provede zarovnání na celou KIR referenci. V prvním kroku je vytvořena statistika obdobně jako v prvním experimentu a odstřiženy alely, které mají menší pokrytí než $CUT_COVERAGE_{ALELS}$ které je uvedené v *configu*. Ze zbylých alel je vytvořena nová reference na kterou je provedeno nové zarovnání readů. Opět je vytvořena statistika. Výsledky této statistiky nalezneme pod

krokem 2. Následuje krok 3 v němž soutěží podobné alely v rámci jednoho genu. Podobnost alel se bere na základě Levenshteinové vzdálenosti. Alely jsou si podobné v případě, kdy je jejich vzdálenost menší než vzdálenost uvedené v *configu* pod parametrem *CLOSE_DISTANCE*. Následuje vytvoření nové reference a nové zarovnání. V posledním kroku 4 jsou v případě kdy gen obsahuje alelu s píkem ostatní odstraněny. Pomocí vzorce kdy porovnávám maximum jejich pokrytí pokud je u jedné dvojnásobné než u druhé tak u té kde je větší vezmu pokud je průměrné pokrytí dané alely dvakrát větší než průměrné pokrytí všech alel v daném genu. Je druhá alela odstraněna.

5.5.5 Překlad alel

Při použití Bowtie vyvstal problém kdy jsou výsledné alely pojmenovány pořadovým číslem jak byli objeveny nikoli názvem vyjadřující jejich skladbu. Proto vznikl modul překlad alel z pořadových čísel do názvů vyjadřující skladbu alely obsahující skript *renaming_alels_result.py*, který projde všechny soubory ve složce pod proměnou *RESULT_FOLDER* a nahradí pořadová čísla příslušným názvem. Nakonec nahradí původní soubor, takto upraveným souborem.

5.6 Nastavení ART a bowtie

pair end 250 dlouhy ready misto MSv3 pouzit MSv1 protoze tak budou i data co dostanu -f 100 pokryti 100 -na značí že nemá vytvořit soubor zarovnání

6 vyhodnocení mezi výsledku a nastavení parametru

tohle asi pak dát spíš k vyhodnocení zarovnání Krok jedna je jen vyhodnocení prvního zarovnání to asi nemá moc smysl sem dávat Krok dva je jenom odstrižení těch který mají menší zarovnání než to udaný v configu Krok tři je odstrižení stejných a Krok 4 je odstrižení průměrů ta tabulka je horzně velká a zasahujeme mi do číslování stránky a i mi přesahuje v pravo. do popisku připsat že krok 2 tak ty vypsaný alely jsou navíc k těm z kroku jedna

Haplotyp	Krok 2			Krok 3		Krok 4	
	Celkem alel	Ztraceno	Geny navíc	Celkem alel	Ztraceno	Celkem alel	Ztraceno
AMALA	164	0 -	0 -	33	2 3DP1*0090101 2DL4*0010201	23	2 -
BOB	170	0 -	1 2DL5B	39	0 -	22	2 3DL2*0070102 2DL4*00501
COX	131	0 -	0 -	24	2 3DL3*0090101 3DP1*006	17	4 2DL4*00501 3DL2*0070103
HO301	140	0 -	0 -	25	3 2DL2*0010103 2DL1*00402 3DL2*0020106	16	4 2DS2*0010104
JVM	154	1 2DL1*0030203	1 2DL1	34	1 -	18	4 3DL3*00801 3DP1*0030202 2DL4*0080101
KAS011	177	0 -	1 2DL5B	37	0 -	23	2 3DL3*0090101 2DL4*00501
OLGA	170	1 3DL1*0010102	1 2DL5B	34	3 2DP1*0020105 3DL2*0070102	17	5 2DL4*00501 3DL1*0050101
RSH	194	0 -	0 -	35	3 2DS2*0010108 2DP1*0020110 2DL1*0030205	15	6 3DL3*0040202 3DL1*0050101 3DL2*023
Test1	121	0 -	0 -	31	0 -	24	0 -

Test2	192	0 -	1 3DS1	33	3 2DP1*0020107 2DL1*0020102 3DL2*0020101	22	3 -
Test3	143	0 -	0 -	29	0 -	16	2 2DL1*0040101 3DL1*002
Test4	148	1 3DL1*0150202	1 3DL1	33	2 3DL2*0020101	18	2 -
Test5	162	1 3DL1*0200101	1 2DL5B	27	3 2DL3*0010109 2DL1*0030208	17	4 2DP1*0030102
Test6	187	0 -	1 2DL5A	43	1 3DP1*0030202	24	2 2DP1*0020103
Test7	170	0 -	0 -	22	7 3DL3*0090103 2DL3*0010103 2DP1*0020106 2DL1*0030205 2DL4*0010201 3DL1*0150203 2DS4*0010107	14	8 3DL2*0020105
Test8	131	0 -	0 -	33	1 2DS2*0010103	27	1 -
Test9	132	1 3DL1*0150208	1 3DL1	34	2 3DL2*0070102	24	2 -
Test10	115	0 -	0 -	30	0 -	21	0
Test11	142	0 -	1 2DL5B	32	1 2DS5*0020103	25	1 -
Průměr	0	0	0				

Tabulka 6.2: Krok 2 Z - ztraceno, snadno oddělitelných (na=příklad pomocí piku), geny navíc

Haplotyp (alel)	Krok 2			Krok 3			Krok 4		
	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc
amala (19)	165	1 3DL1*0150201	1 3DL1	33	2 2DL4*0010201	1 -	20	3 3DL2*0020105	1 -
bob (19)	169	0 -	1 2DL5B	38	0 -	1 -	21	2 2DL4*00501 3DL2*0070102	1 -
cox (19)	131	0 -	0 -	27	1 3DL3*0090101	0 -	18	3 2DL4*00501 3DL2*0070103	0 -
ho301 (24)	138	0 -	0 -	25	3 3DL2*0020106 2DL1*00402 2DL2*0010103	0 -	16	4 2DS2*0010104	0 -
jvm (17)	156	0 -	0 -	33	1 2DL4*0080101	0 -	16	3 3DL3*00801 3DP1*0030202	0 -
kas011 (20)	177	0 -	1 2DL5B	39	0 -	1 -	22	2 3DL3*0090101 2DL4*00501	1 -
olga (21)	177	0 -	1 2DL5B	36	1 2DP1*0020105	1 -	19	3 2DL4*00501 3DL1*0050101	1 -
rsh (20)	196	0 -	1 2DL5A	40	2 2DL1*0030205 2DP1*0020110	1 -	20	4 3DL3*0040202 3DL1*0050101	1 -
test1 (23)	115	1 3DL1*0150101	0 -	30	1 -	0 -	21	2 2DP1*0010203	0 -
test2 (21)	190	0 -	0 -	35	1 2DL1*0020102	0 -	24	1 -	0 -
test3 (16)	149	0 -	0 -	29	0 -	0 -	18	1 2DL1*0040101	0 -

test4 (18)	151	0 -	0 -	32	2	2DS1*0020101 3DL2*0020101	1 2DS1	17	2 -	1 -
test5 (19)	163	1 3DL1*0200101	2 3DL1 2DL5B	30	2	2DL1*0030208	2 -	18	2 -	2 -
test6 (21)	198	0 -	1 2DL5A	45	1	3DP1*0030202	1 -	26	3 2DP1*0020103 3DL3*0140203	1 -
test7 (18)	176	0 -	0 -	22	7	2DP1*0020106 2DL3*0010103 3DL3*0090103 2DL1*0030204 3DL1*0150203 2DL4*0010201 2DS4*0010107	0 -	14	8 3DL2*0020105	0 -
test8 (24)	130	0 -	0 -	35	1	2DS2*0010103	0 -	25	2 3DL2*0070102	0 -
test9 (22)	131	1 3DL1*0150208	1 3DL1	34	1	-	1 -	27	2 3DL2*0070102	1 -
test10 (21)	114	0 -	1 2DL5A	32	0	-	1 -	22	0 -	1 -
test11 (24)	141	0 -	1 2DL5B	32	1	3DL2*0070102	1 -	26	1 -	1 -

Tabulka 6.4: Experiment 2 vygenerovano Krok 2 Z - ztraceno, snadno oddělitelných (na=příklad pomocí piku), geny navíc

Haplotyp (alel)	Krok 2			Krok 3			Krok 4		
	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc
amala (19)	220	1 3DL1*0150201	1 3DL1	34	3 2DL4*0010201 3DP1*0090101	1 -	22	3 -	1 -
bob (19)	220	0 -	1 2DL5B	36	1 2DS1*0020101	2 2DS1	19	3 3DL2*0070102 2DL4*00501	2 -
cox (19)	154	0 -	0 -	23	2 3DL3*0090101 3DP1*006	0 -	17	3 2DL4*00501	0 -
ho301 (24)	170	0 -	1 2DL5A	29	2 2DL2*0010103 2DL1*00402	1 -	18	3 2DS2*0010104	1 -
jvm (17)	194	0 -	0 -	35	0 -	0 -	15	3 3DL3*00801 3DP1*0030202 2DL4*0080101	0 -
kas011 (20)	195	0 -	1 2DL5B	40	0 -	1 -	21	2 2DL4*00501 3DL3*0090101	1 -
olga (21)	187	0 -	1 2DL5B	32	1 2DP1*0020105	1 -	18	3 2DL4*00501 3DL1*0050101	1 -
rsh (20)	234	0 -	1 2DL5A	38	2 2DL1*0030205 2DP1*0020110	1 -	20	5 3DL2*023 3DL1*0050101 3DL3*0040202	1 -
test1 (23)	162	1 3DL1*0150101	0 -	29	1 -	0 -	19	2 2DP1*0010203	0 -

test2 (21)	207	0 -	0 -	34	2	2DP1*0020107 2DL1*0020102	0 -	22	3	3DL3*019	0 -
test3 (16)	191	0 -	0 -	29	1	2DL4*0010306	0 -	16	2	2DL1*0040101	0 -
test4 (18)	175	0 -	0 -	30	1	3DL2*0020101	0 -	17	1	-	0 -
test5 (19)	209	0 -	1 2DL5B	30	1	2DL1*0030208	1 -	18	1	-	1 -
test6 (21)	258	0 -	1 2DL5A	42	1	3DP1*0030202	1 -	24	3	3DL3*0140203 2DP1*0020103	1 -
test7 (18)	185	0 -	0 -	23	8	2DL1*0030205 2DL4*0010201 2DP1*0020106 3DL2*0020105 3DL1*0150203 2DS4*0010107 2DL3*0010103 3DL3*0090103	0 -	14	8	-	0 -
test8 (24)	144	0 -	0 -	35	1	2DS2*0010103	0 -	26	2	3DL2*0070102	0 -
test9 (22)	158	1 3DL1*0150208	1 3DL1	36	1	-	1 -	25	2	3DL2*0070102	1 -
test10 (21)	178	0 -	1 2DL5A	31	0	-	1 -	21	0	-	1 -
test11 (24)	153	0 -	1 2DL5B	33	1	3DL2*0070102	1 -	27	1	-	1 -

Tabulka 6.6: Experiment 3 shluky s menší mezerou než 15, coverage 75

Haplotyp (alel)	Krok 2			Krok 3			Krok 4		
	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc
amala (19)	235	0 -	0 -	39	2 3DP1*0090101 2DL4*0010201	0 -	21	3 3DL2*0020105	0 -
bob (19)	250	0 -	1 2DL5B	45	0 -	1 -	22	2 2DL4*00501 3DL2*0070102	1 -
cox (19)	210	0 -	0 -	27	1 3DL3*0090101	0 -	22	3 2DL4*00501 3DL2*0070103	0 -
ho301 (24)	179	0 -	2 2DS1 2DL5A	32	3 3DL2*0020106 2DL2*0010103 2DL1*00402	2 -	20	4 2DS2*0010104	2 -
jvm (17)	228	0 -	0 -	37	0 -	0 -	15	3 3DL3*00801 3DP1*0030202 2DL4*0080101	0 -
kas011 (20)	222	0 -	1 2DL5B	41	0 -	1 -	24	2 3DL3*0090101 2DL4*00501	1 -
olga (21)	203	0 -	1 2DL5B	35	2 3DL2*0070102 2DP1*0020105	1 -	18	4 2DL4*00501 3DL1*0050101	1 -
rsh (20)	273	0 -	1 2DL5A	46	2 2DL1*0030205 2DP1*0020110	1 -	22	4 3DL3*0040202 3DL1*0050101	1 -
test1 (23)	185	0 -	0 -	35	0 -	0 -	22	2 3DL3*0030101 2DP1*0010203	0 -

test2 (21)	209	0 -	0 -	36	2	2DL1*0020102 2DP1*0020107	0 -	25	2 -	0 -
test3 (16)	204	0 -	0 -	26	1	2DL4*0010306	0 -	14	2 2DL1*0040101	0 -
test4 (18)	205	0 -	0 -	36	1	3DL2*0020101	0 -	18	1 -	0 -
test5 (19)	228	0 -	1 2DL5B	32	1	2DL1*0030208	1 -	20	1 -	1 -
test6 (21)	275	0 -	1 2DL5A	45	1	3DP1*0030202	1 -	23	3 2DP1*0020103 3DL3*0140203	1 -
test7 (18)	199	0 -	0 -	23	7	3DL3*0090103 2DP1*0020106 2DS4*0010107 2DL4*0010201 3DL1*0150203 2DL1*0030205 2DL3*0010103	0 -	13	8 3DL2*0020105	0 -
test8 (24)	146	0 -	0 -	34	1	2DS2*0010103	0 -	24	2 3DL2*0070102	0 -
test9 (22)	172	1 3DL1*0150208	1 3DL1	38	2	2DS2*0010112	1 -	25	3 3DL2*0070102	1 -
test10 (21)	198	0 -	1 2DL5A	34	0	-	1 -	24	0 -	1 -
test11 (24)	156	0 -	1 2DL5B	34	2	3DL2*0070102 2DS5*0020103	1 -	27	2 -	1 -

Tabulka 6.8: Experiment 3 shluky s menší mezerou než 15, coverage 70

Haplotyp (alel)	Krok 2			Krok 3			Krok 4		
	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc	Zbývá alel	Ztraceno	Geny navíc
amala (19)	238	0 -	0 -	40	2 2DL4*0010201 3DP1*0090101	0 -	22	3 3DL2*0020105	0 -
bob (19)	253	0 -	1 2DL5B	44	0 -	1 -	24	1 2DL4*00501	1 -
cox (19)	210	0 -	0 -	27	1 3DL3*0090101	0 -	22	3 2DL4*00501 3DL2*0070103	0 -
ho301 (24)	183	0 -	2 2DL5A 2DS1	33	2 2DL1*00402 2DL2*0010103	2 -	21	3 2DS2*0010104	2 -
jvm (17)	240	0 -	0 -	37	0 -	0 -	15	3 3DL3*00801 3DP1*0030202 2DL4*0080101	0 -
kas011 (20)	242	0 -	1 2DL5B	42	0 -	1 -	24	2 2DL4*00501 3DL3*0090101	1 -
olga (21)	203	0 -	1 2DL5B	35	2 3DL2*0070102 2DP1*0020105	1 -	18	4 3DL1*0050101 2DL4*00501	1 -
rsh (20)	276	0 -	1 2DL5A	44	2 2DP1*0020110 2DL1*0030205	1 -	20	4 3DL3*0040202 3DL1*0050101	1 -
test1 (23)	186	0 -	0 -	32	0 -	0 -	20	2 2DP1*0010203 3DL3*0030101	0 -
test2 (21)	209	0 -	0 -	35	2 2DL1*0020102 2DP1*0020107	0 -	25	2 -	0 -

test3 (16)	207	0 -	0 -	28	1	2DL4*0010306	0 -	17	2	2DL1*0040101	0 -
test4 (18)	207	0 -	0 -	35	1	3DL2*0020101	0 -	18	1	-	0 -
test5 (19)	230	0 -	1 2DL5B	32	1	2DL1*0030208	1 -	19	1	-	1 -
test6 (21)	278	0 -	1 2DL5A	47	1	3DP1*0030202	1 -	23	4	2DL1*0030203 3DL3*0140203 2DP1*0020103	1 -
test7 (18)	200	0 -	0 -	26	7	2DL3*0010103 2DL1*0030205 2DL4*0010201 3DL1*0150203 2DS4*0010107 3DL3*0090103 2DP1*0020106	0 -	13	8	3DL2*0020105	0 -
test8 (24)	146	0 -	0 -	34	1	2DS2*0010103	0 -	24	2	3DL2*0070102	0 -
test9 (22)	174	1 3DL1*0150208	1 3DL1	39	1	-	1 -	28	2	3DL2*0070102	1 -
test10 (21)	201	0 -	1 2DL5A	34	0	-	1 -	24	0	-	1 -
test11 (24)	156	0 -	1 2DL5B	34	2	3DL2*0070102 2DS5*0020103	1 -	27	2	-	1 -

Tabulka 6.10: Experiment 3 shluky s menší mezerou než 20, coverage 70

7 Vyhodnocení výsledků a jejich srovnání

8 Závěr

V práci bylo řešeno

- V teoretické části byli popsány a rozbrány Geny

- V realizační části byl navržen a implementován program v jazyce Python

- Parametry ARTU byli nastaveny na základě dat z FN protože používají zrovna tenhle sekvenátor

- Testování bylo prováděno na syntetických readech a následná validace byla provedena na datech z FN

- Do budoucna by to chtělo co? vylepšení zhodnocení výsledků?

9 Výkladový slovník pojmů a zkratek

WHO	World health organization, světová zdravotnická organizace
ČNRDD	Český národní registr dárců kostní dřeně
MHC	Major histocompatibility complex, genetický systém
HLA	Human leucocyte antigen, podskupina MHC
KIR	Killer immunoglobulin like-receptor, skupina genů
NK	Natural killer, buňka imunitního systému
DNA	Deoxyribonukleová kyselina; dvoušroubovice, která obsahuje páry bází C, G, A, T
RNA	Ribonuklové kyselina; obsahuje báze C, G, A, U; šablona přímo pro vytvoření proteinů; hlavní funkcí zajištění překladu DNA do struktury proteinů (DNA -> mRNA -> rRNA -> tRNA -> RNA)
Báze	nukleové báze; A - Adenin, C - Cytosin, G - Guanin, T - Thymin
bp	base pair; jeden z párů A - T nebo C - G
kb	kilobase 1 kb = 1000 bp
ART	nástroj na vytváření syntetických readů
Bowtie	nástroj na zarovnání readů proti referenčním genům
SAM	Sequence Alignment/Map; Formát souboru na uložení zarovnání
BAM	Binární verze souboru SAM
Fenotyp	adwda
Genotyp	adawwd

TODO tímhle si nejsem moc jistá tak jsem to pochopila je to dobře?
DNA -> mRNA -> rRNA -> tRNA -> RNA

TODO co ty formáty souboru?

fenotyp tyhle kraviny Genotyp pro danou chromozomální oblast se pak u většiny lidí skládá ze dvou haplotypů). genom kompletní sekvence daného organismu

DNA (Deoxyribonukleová kyselina)

- dvoušroubovice, která obsahuje páry bází C, G, A, T

obojí obsahuje nukleotidy bází? Rozdíl mezi DNA a RNA DNA dvoušroubovice, která obsahuje páry bází - C G A T, kdežto RNA je již šablona přímo pro vytvoření proteinů takže jedna půlka šroubovice bez intronů. Hlavní funkcí RNA je zajištění překladu genetického kódu (DNA) do struktury proteinů nejdřív je DNA mRNA, rRNA tRNA RNA

Co znamená konec 3 a konec 5?

Literatura

- [1] *Chromosome* [online]. [cit. 2020/12/3]. Dostupné z:
<https://www.genome.gov/genetics-glossary/Chromosome>.
- [2] *DNA sequencing Fact Sheet* [online]. [cit. 2019/03/1]. Dostupné z:
<https://www.genome.gov/about-genomics/fact-sheets/DNA-Sequencing-Fact-Sheet>.
- [3] *S transplantací kostní dřeně stále častěji pomáhají příbuzní* [online].
Dostupné z: <https://ct24.ceskatelevize.cz/domaci/2527141-s-transplantaci-kostni-drene-stale-casteji-pomahaji-pribuzni>.
- [4] *Basic genetics* [online]. [cit. 2020/12/3]. Dostupné z:
<https://kintalk.org/genetics-101/>.
- [5] *Illumina* [online]. [cit. 2019/03/1]. Dostupné z:
<https://www.illumina.com/>.
- [6] *KIR genotypes* [online]. Dostupné z:
<http://www.allelefrequencys.net/kir6001a.asp>.
- [7] *What is the best NGS alignment software?* [online]. Dostupné z:
<https://www.ecseq.com/support/ngs/what-is-the-best-ngs-alignment-software>.
- [8] BARANWAL, A. – MEHRA, N. Major Histocompatibility Complex Class I Chain-Related A (MICA) Molecules: Relevance in Solid Organ Transplantation. *Frontiers in Immunology*. 02 2017, 8. doi: 10.3389/fimmu.2017.00182.
- [9] BERNAREGGI, D. – POUYANFARD, S. – KAUFMAN, D. S. Development of innate immune cells from human pluripotent stem cells. 2019. Dostupné z:
<https://www.sciencedirect.com/science/article/pii/S0301472X19300037?via%3Dihub>.
- [10] COOLEY, S. – WISDORF, D. J. – GUETHLEIN, L. A. Donor selection for natural killer cell receptor genes leads to superior survival after unrelated transplantation for acute myelogenous leukemia. 2010. Dostupné z:
<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2953880/>.
- [11] ESCALONA, M. – ROCHA, S. – POSADA1, D. A comparison of tools for the simulation of genomic next-generation sequencing data. 2016. Dostupné z:
<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC5224698/#>.

- [12] FRYČOVÁ, M. Lze u pacientů s AML indikovaných k nepříbuzenské transplantaci provádět v klinické praxi výběr nepříbuzných dárců na základě KIR genotypů, 2016.
- [13] HERNYCHOVÁ, L. Receptory NK buněk. 2012.
- [14] HUANG, W. et al. ART: a next-generation sequencing read simulator. 2012. Dostupné z: <https://academic.oup.com/bioinformatics/article/28/4/593/213322>.
- [15] J, R. et al. *Nomenclature* [online]. Nucleic Acids Research, 2015. [cit. 2019/10/1]. 43:D423-431. Dostupné z: <http://hla.alleles.org/misc/citing.html>.
- [16] KOLÍSKO, M. Moderní metody sekvenování DNA. 2017. Dostupné z: <https://ziva.avcr.cz/files/ziva/pdf/moderni-metody-sekvenovani-dna.pdf>.
- [17] LANGMEAD, B. [online]. [cit. 2019/03/1]. Dostupné z: <http://www.langmead-lab.org/>.
- [18] LANGMEAD, B. – SALZBERG, S. L. Fast gapped-read alignment with Bowtie 2. 2012. Dostupné z: https://www.researchgate.net/publication/221886241_Langmead_B_Salzberg_SL_Fast_gapped-read_alignment_with_Bowtie_2_Nat_Methods_9_357-359.
- [19] LANGMEAD, B. et al. Ultrafast and memory-efficient alignment of short DNA sequences to the human genome. 2009. Dostupné z: <https://genomebiology.biomedcentral.com/articles/10.1186/gb-2009-10-3-r25>.
- [20] MERZKER, M. L. Sequencing technologies-the next generation. 2013. doi: 10.1038/nrg2626.
- [21] MUDR. PAVEL JINDRA, P. D. *Imunopatologické a imunogenetické aspekty transplantací krevetvorných buněk a solidních orgánů*. PhD thesis, Universita Karlova v Praze, 2011.
- [22] PAPOUŠEK, I. Elektroforéza nukleových kyselin. 2017. Dostupné z: https://fvhe.vfu.cz/files/mbhp_2018_02.pdf.
- [23] PENDE, D. et al. *Killer Ig-Like Receptors (KIRs): Their Role in NK Cell Modulation and Developments Leading to Their Clinical Exploitation* [online]. 2019. Dostupné z: <https://www.frontiersin.org/articles/10.3389/fimmu.2019.01179/full>.

- [24] PENKA, M. – KOLEKTIV, E. T. *Hematologie a transfuzní lékařství II*. 2012. ISBN 978-80-247-3460-6.
- [25] ROBINSON, J. et al. IPD—the Immuno Polymorphism Database. 2013. Dostupné z: <https://www.ebi.ac.uk/ipd/index.html>.
- [26] ROBINSON, J. et al. The IPD and IMGT/HLA Database:allele variant databases. 2015. Dostupné z: <https://www.ebi.ac.uk/ipd/index.html>.
- [27] S.KANNANA, G. – ARIANEXYSAQUINO-LOPEZ – A.LEED, D. Natural killer cells in malignant hematology: A primer for the non-immunologist. 2017. Dostupné z: <https://www.sciencedirect.com/science/article/pii/S0268960X16300704>.
- [28] SMITH, D. T. *Encyklopedie lidského těla*. 2005. ISBN 80-7321-156-4.
- [29] THIELENS, A. – VIVIER, E. – ROMAGNÉ, F. NK cell MHC class I specific receptors (KIR): from biology to clinical intervention. *Current opinion in immunology*. 2012, 24 2, s. 239–45.
- [30] VODSLOŇ, F. Vyhodnocování podobnosti zdrojových textů, 2007.

A Uživatelská dokumentace

Program byl napsán a otestován za použití ART ve verzi MountRainier, Bowtie 2 ve verzi 2.4.1, Python ve verzi 3.8. Dále byla použita pytnovská knihovny pysam ve verzi 0.14.

Následující postupy jsou uvedeny pro operační systém Linux a pro jiné operační systémy se mohou lišit. Veškeré nastavení aplikace probíhá pomocí souboru *config.py*

Parametry configu:

- CREATE_READS - Značí zda má být spuštěn modul vytvoření syntetických readů. Očekávaný hodnota je True nebo False.
- ALIGN - Značí zda má být spuštěn modul pro zarovnání readů vzhledem k referenčním genům. Očekávaná hodnota je True nebo False.
- EVALUATE - Značí zda má být spuštěno vyhodnocení zarovnaných readů. Očekávaná hodnota je True nebo False.
- REFERENCE_KIR_GENS_FOLDER - Referenční geny by měli obsahovat cestu k složce ve které se nachází referenční geny.
- REFERENCE_KIR_GENS_PSEUDOGENS_FILE - Dodatečný soubor, který se bude prohledávat v případě že gen nebude nalezen ve složce REFERENCE_KIR_GENS_FOLDER. Typickým příkladem mohou být pseudogeny.
- HAPLOTYPE_FOLDER - Označuje cestu složky do které jsou ukládány vytvořené haplotypy.
- HAPLOTYPES - Slovník, který definuje haplotypy podle obsahů genů. Na základě toho budou vytvořeny haplotypy.
- BOWTIE_HOME_DIRECTORY - Označuje cestu ke nástroji Bowtie.
- READS_FOLDER - Označuje složku do které budou ukládány ready. Případně z které budou načítány.

- BOWTIE_INDEX_FOLDER - Označuje složku do které budou ukládány indexy z Bowtie. Případně z které budou načítány.
- BOWTIE_BUILD_INDEX - Značí zda mají být vytvořeny Bowtie indexy. Pokud bude hodnota nastavena na False, musí být přítomny indexy z minulého běhu, jinak zarovnávání nebude fungovat. Očekávaná hodnota je True nebo False.
- BOWTIE_THREADS - Počet vláken na která má být Bowtie spuštěn.
- ALIGNMENT_FOLDER - Označuje složku do které budou ukládány zarovnané ready. Případně z které budou načítány.
- BAM_FOLDER - Označuje složku na uložení BAM souborů.
- RESULT_FOLDER - Označuje složku do které budou uloženy výsledky vyhodnocení zarovnání.

A.1 Spuštění programu

Program je možné spustit z příkazové řádky pomocí příkazu *python run.py*. Podmínkou fungování tohoto postupu je, že je třeba se nacházet v umístění skriptu.

A.2 Doporučená adresářová struktura pro data

- data
 - alignments
 - bam
 - bowtie_index
 - haplotype
 - reads
 - result

A.3 Výstupy programu

V případě tvorby vlastních haplotypů s doporučenou adresářovou strukturou najdeme ve složce *haplotype* soubory s příponou *.fa*. Každý soubor obsahuje

jeden haplotyp. Vytvořené ready se budou nacházet ve složce reads. Protože haplotypy jsou paired-end náleží každému haplotypu dva soubory s příponou *.fq*. Jeden s 1 na konci a druhý s 2 na konci. V případě zarovnání mohou být výstupní soubory indexy ve složce *bowtie_index*. Kdy pro každý referenční gen je vytvořeno 6 souborů s příponou *bt2*. Výsledné zarovnání se pak nachází ve složce *alignments* ve formátu *.sam*. Vyhodnocení zarovnání se pak nachází ve složce *result* ve formátu *.txt*

A.4 Nastavení ART a jeho spuštění

tak jsem stáhla normálně nejnovější verzi z niehs.nih.gov a podle instrukcí co byli v souboru *INSTAL* dala

A.4.1 pokus to nějak spustit

Takže když otevru hlavní readme tak mi to říká že tam jsou read me pro jednotlivé verze sekvenátoru ..

pak se to musí skompilovat

`./configure --prefix=$HOME make make install`

teď mě zajímá ta ilumina tak podle readme ilumina tak můžu vlést do složky examples a tam pustit skript `run_test_examples_illumina.sh`, tak tam jsou 4 příklady použití a pokud asi všechno dobře proběhne tak se mi zobrazí pár nových souborů ve složce examples..

FASTQ - *.fq data file s ready. pro paired-red simulator *1.fq obsahuje data pro první ready a *2.fq druhý ready

tohle nějak funguje MSv3 tam musím dát abych to mohla dostat na délku readu 250 a p znací ze to je paired.. tak se má používat MSv1 *art_illumina-ssMSv3-sam-iamplicon_reference.fa-p-l250-f10-m300-s10-omoje_art_data* Tohle používej: *art_illumina-ssMSv1-sam-iamplicon_reference.fa-p-l250-f100-m300-s10-omoje_art_data*

A.5 Bowtie

a stáhla jsem to tedy po kliknutí na bowtie binary release.

na stránce 25.4 je řečeno o hledání těch nejlepších zarovnání a je tam možnost `-best` ale že je dvakrát nebo třikrát pomalejší než normální mod.. a jde o to že najde první přijatelný a to označí kdežto při tom `best` prohledá co nejvíce a hledá to nejlepší i mezi těma přijatelnýma a to je pomalý.

tak jsem to stáhla dala do složky a musela jsem teda nastavit proměnou prostředí export BT2_HOME=/home/kate/Dokumenty/FAV/Diplomka/existujicisw/bowtie 2.4.1 – linux – x86₆₄/ pak jsem pustila tohle: \$BT2_HOME/bowtie2-build \$ BT2_HOME/example/reference/lambda_virus.falambda_virus a nakonec se mi vytvořili nějaký nové soubory lambda virus 1 atd.. v tom bowtie 2 adresáři

dělala jsem o podle tohoto webovky

indexy bowtie-build builds a Bowtie index from a set of DNA sequences. bowtie-build outputs a set of 6 files with suffixes .1.ebwt, .2.ebwt, .3.ebwt, .4.ebwt, .rev.1.ebwt, and .rev.2.ebwt. (If the total length of all the input sequences is greater than about 4 billion, then the index files will end in ebwtl instead of ebwt.) These files together constitute the index: they are all that is needed to align reads to that reference. The original sequence files are no longer used by Bowtie once the index is built.

A.6 Používané soubory

A.6.1 FASTQ

aln_start_pos označuje počáteční pozici v referenci sekvence, je vždy relativní vzhledem k vláknům referenční sekvence To znamená že aln_start_pos plus (10) vláknem je odlišný od aln_start_pos minus (-) vláknem.. ??? WHAT???

ref_seq_aligned je zarovnaná oblast referenční sekvence, která může být plus vláknem nebo mínus vláknem referenční sekvence ref_seq_aligned je zarovnaný read, který je vždy ve stejné orientaci jako stejný read v odpovídajícím fastq suboru.

aln_start_pos is the alignment start position of reference sequence. aln_start_pos is always relative to the strand of reference sequence. That is, aln_start_pos 10 in the plus (+) strand is different from aln_start_pos 10 in the minus (-) strand.

ref_seq_aligned is the aligned region of reference sequence, which can be from plus strand or minus strand of the reference sequence. read_seq_aligned is the aligned sequence read, which always in the same orientation of the same read in the corresponding fastq file.

SAM je standardní formát pro NG sekvence ready zarování BED o tom tam nic není jen NOTE: both ALN and BED format files use 0-based coordinate system while SAM format uses 1-based coordinate system.

pak jsou tady 4 doporučené použití *art_illumina[options] -ss < sequencing_system > -sam -i < seq_ref_file > -l < read_length > -f < fold_coverage > -o < outfile_prefix > art_illumina[options] -ss < sequencing_system >*

```

-sam -i < seq_reffile > -l < read_length > -c < num_reads_per_sequence >
-o < outfile_prefix > art_illumina[options] -ss < sequencing_system >
-sam -i < seq_reffile > -l < read_length > -f < fold_coverage >
-m < mean_fragsize > -s < std_fragsize > -o < outfile_prefix >
art_illumina[options] -ss < sequencing_system > -sam -i < seq_reffile >
-l < read_length > -c < num_reads_per_sequence > -m < mean_fragsize >
-s < std_fragsize > -o < outfile_prefix >

```

A.6.2 FASTQ

Sekvenační přístroje produkují data ve formátu FASTQ takže i ART musí logicky generovat tenhle formát. Pokud jsou ready v páru tak je na konci .1 a druhý read z páru tam má .2 to jsem u těch svých přímo nenašla

ale máš teda tři druhy single end, paired-end a matepair.

FASTQ obsahuje obě základy sekvence ?? both sequence bases a kvality skóre je to v následujícím formátu @read_id sequence read + base quality scores je kódovány by ascii code of a single character, kde je kvalita rovná score to ascii code character minus 33. chápu proč tam je to -33 protože když se podíváš do asci tabulky tak je tam od 33 první normální znak jinak jsou tam divný .. takže třeba otazník je v asci na 63 takže -33 takže má ohodnocení kvality 30 jen by mě teda zajímalo v jakém sme intervalu? - je 45 v asci a nevím jestli to je teda od 0 do 100? a teda nejvyšší číslo znamená nejkvalitnější a nejmenší mín kvalitní? Podle té diplomky to tak je že čím vyšší číslo tím kvalitnější a většinou je to od 0 do 40 jen zřídka to překročí hodnotu 60, když je tam 10 tak to znamená že jedna báze z deset je špatně.. když je tam 30 tak to znamená že jedna z 1000 je špatně. já tam mám třeba F a to je 70.

example: @refid-4028550-1 caacgccactcagcaatgatcggtttattcacgat... +

ALN - zarovnání readů zase *1.aln pro první a *2.aln pro druhý soubor je rozdělen na hlavičku a body část obsahuje hlavičku a v té hlavičce je jakým příkazem byl soubor vygenerován a reference na sequeunce id a jejich délku @CM tag pro příkaz a @SQ pro reference sequence Hlavička vždycky začíná s

HEADER EXAMPLE

B Detailní výsledky

B.1 Experiment1

Genotyp	Alel	Krok 1				Geny navíc	Krok 2			Geny navíc	Krok 3			Geny navíc		
		Zbývá alel	Ztraceno				Zbývá alel	Ztraceno			Zbývá alel	Ztraceno				
amala	19 (0)	461	0	-	2	2DL5B 2DS3	113	2	2DL1*0030201 3DL1*0150201	0	-	24	3	3DP1*0090101	0	-
bob	19 (0)	461	0	-	2	2DL5B 2DS3	103	2	2DL1*0030210 3DL1*002	0	-	27	2	-	0	-
cox	19 (2)	461	0	-	5	2DS3 2DL2 2DL5B 2DS2 2DL5A	74	0	-	0	-	19	2	3DP1*006 3DL3*0090101	0	-
ho301	24 (6)	461	0	-	5	2DS1 2DL5A 2DS5 2DL3 3DS1	86	0	-	0	-	21	4	2DL2*0010103 3DL2*0020106 2DS3*0020103 2DL1*00402	0	-
jvm	17 (1)	461	0	-	6	2DL5B 2DS1 3DS1 2DL5A 2DS5 2DS3	66	3	2DL1*0030203 3DL1*0010104 3DL1*008	0	-	22	3	-	0	-
kas011	20 (1)	461	0	-	4	2DL5B 2DS3 2DL2 2DS2	97	2	3DL1*008 2DL1*0020101	0	-	30	3	3DL2*01001	0	-
olga	21 (3)	461	0	-	4	2DL5B 2DS3 2DL2 2DS2	95	1	3DL1*0010102	0	-	25	2	2DP1*0020105	0	-
rsh	20 (0)	461	0	-	4	2DL5A 2DS1 2DS3 3DS1	92	3	3DL1*01701 2DL4*0010307 2DL1*0030205	0	-	24	4	2DP1*0020110	0	-
test1	23 (3)	461	0	-	1	2DS5	69	2	3DL1*0150101 2DL1*0030203	0	-	27	2	-	0	-
test2	21 (1)	461	0	-	2	2DS3 2DS2	83	1	3DL1*0070101	0	-	23	3	3DL2*0020101 2DL1*0020102	0	-

test3	16 (1)	461	0	-	9	2DS1 2DL2 2DL5A 3DS1 2DS2 2DL5B 2DS5 2DS4 2DS3	79	2	2DL1*008 3DL1*002	0	-	18	3	2DL4*0010306	0	-
test4	18 (0)	461	0	-	3	2DL5A 2DL5B 2DS3	101	2	3DL1*0150202 2DL4*0010307	0	-	23	3	3DL2*0020101	0	-
test5	19 (1)	461	0	-	5	2DL5B 2DL2 2DS4 2DS2 2DS5	86	1	3DL1*0200101	0	-	22	2	2DL1*0030208	0	-
test6	21 (0)	461	0	-	4	2DL5A 2DS1 2DS5 3DS1	99	2	3DL1*0250102 2DL1*0030203	0	-	29	3	3DP1*0030202	0	-
test7	18 (1)	461	0	-	8	2DS1 2DL2 3DS1 2DS2 2DL5B 2DS5 2DL5A 2DS3	97	2	3DL1*0150203 3DL1*008	0	-	13	8	2DL3*0010103 2DP1*0020106 2DS4*0010107 3DL3*0090103 2DL1*0030205 2DL4*0010201	0	-
test8	24 (2)	461	0	-	4	3DL1 2DS5 2DS4 2DL3	97	1	2DL4*00104	0	-	26	2	2DS3*0020101	0	-
test9	22 (1)	461	0	-	2	2DS5 2DL3	99	2	2DL4*00104 3DL1*0150208	0	-	25	3	3DL3*0030103	0	-
test10	21 (3)	461	0	-	3	2DL5A 2DS5 2DS4	69	3	3DL1*0150101 2DL1*0030203 2DL4*010	0	-	25	3	-	0	-
test11	24 (2)	461	0	-	5	2DL5B 3DL1 2DS3 2DS4 2DL3	110	0	-	0	-	26	2	2DS5*0020103 3DL3*0030103	0	-

Tabulka B.2: Výsledky experimentu1. Odřezány byly alely, které měli pokrytí menší než 90%. Alel u genotypu značí počet v daném genotypu. Číslo v závorkách udává kolik alel je dvakrát v daném genotypu. V každém kroku zbývá alel je z kolik alel ještě zůstalo ve výběru, ztraceno určuje kolik alel má být v genotypu, ale algoritmus je vyřadil. Za tímto číslem jsou vypsané alely které byly ztraceny. V dalších krocích jsou vypsané alely bez těch které už byly ztraceny v předchozích krocích. Obdobně je to s geny navíc, které udávají počet a jaké geny již neobsahují žádnou z alel, která náleží do daného genomu.

C Vyhodit

TODO vyhodit? Doposud nebylo zavedeno konkrétní pravidlo na pojmenování KIR genů. Avšak bylo navrženo, aby každý KIR haplotyp byl označen "*KH* – " následovaným trojmístným číslem, které bude označovat konkrétní haplotyp. Bylo by tak možné pojmenovat 999 haplotypů. Dále by bylo označeno do které ze dvou skupin A či B haplotyp patří. Skupina B musí obsahovat alespoň jeden z genů KIR2DL5, KIR2DS1, KIR2DS2, KIR2DS3, KIR2DS5 a KIR3DS1. Naopak skupina A neobsahuje ani jeden z těchto genů. Z tohoto pravidla je patrné, že haplotypy B mají vždy více aktivních KIR než haplotypy A. Za trojmístným číslem by tedy dále bylo písmeno A nebo B. Nakonec by byl připojen 17-ti místný binární kód, který by označoval přítomnost "1" či absenci "0" genu. Pořadí genů by odpovídalo pořadí v genomu od centrometrické části k telemetrické části. [26]

Výsledné pojmenování by mohlo vypadat následovně:

$$KH - 001A - 11100010011011011 \quad (C.0.1)$$

Analogicky by bylo pojmenování KIR genotypů. Označení by začínalo "*KG* – " následovaným čtyřmístným unikátním číslem označující daný genotyp. V neposlední řadě by opět byl 17-ti místní binární kód označující přítomnost či absenci KIR genu.

TODO možná informaci o B-content score za tohle, proč u více shodných se řeší KIR, že se vybírají B haplotypový dárce a že v poslední době se řeší, zda kromě haplotypu nemají vliv konkrétní alelické varianty KIR genů (to je to, proč vy to řešíte v diplomce) - s tímhle ještě moc nevím co budu dělat.

454 je sekvenování při kterém se zachycuje vyzářené světlo na základě toho pokud se báze přidala do řetězce či nikoliv. Jeho dominantní chybou je tedy nesprávné určení počtů přidávaných bází. Pravděpodobnost chyby roste s frekvencí dlouhých úseků obsahující stejnou bázi. Proto ART modeluje rozdělení chyb na základě délky úseku obsahující stejnou bázi spolu s Markovovy řetězcí.

SOLid je založené na označení čtyř barev pro 16 různých skupin bází. Pro paired-end read simulaci délky fragmentu je použito Gausovské rozdělení. Rozdělení chyb je založeno na empirické znalosti získané z readů genero-

vaných Applied Biosystemem. ART zároveň nabází nastavené chybovosti základě lineárního měřítka.

Podle [14] je dostupných několik nástrojů pro simulaci NGS dat (Wgsim, MetaSim, SimSeq, FlowSim), které fungují dobře pro sekvenátory pro které byli určeny, ale žádný z nich se nedokázal vypořádat se všemi nejvíce používanými. Jejich slabinou je především v generování chyb na základě jednotlivých módů konkrétního sekvenátoru. Nejčastější chyby jsou substituční a vložení či smazání (INDEL - insert-deletion). ART obsahuje technologické profily chyb a navíc mu může použít i uživatelský profil chyb. Profily které obsahují délky readů a chyby byly získány z datasetu skutečných sekvenovaných dat.

TODO možná napsat co znamenají konkrétní chyby

TODO Proč? No protože přesně ví co tam dávají za data, protože mu podšoupnou ten referenční genom a tak pak můžou dobře sledovat co ten zarovnávač s tím dělá. A proč je to o tolik výhodnější než když by měli nějaký realnej dataset? Možná že si tam můžou ty chyby navolit tak jak se jim hodí? Jako bude v tom míň chyb, ale stejně.

Počítání jen pokrytí za použití `pysam.coverage` či co nevím jestli se nějak víc štourat v těch bowtie nastavení.. u `artu` to nemá smysl protože tam se hlavně musím držet toho aby byli co nejvíc podobný těm z nemocnice bowtie se to snaží někam dát za každou cenu.

zkoušela jsem v pythonu přes `pysam.depth`, zkusit nějaký odhad na alely.